6. Sesión 3 - Fundamentos de Ingeniería de Datos

Resumen de la Sesión

En esta sesión exploramos el "motor" de la analítica. Aprenderemos cómo se capturan, integran y gestionan los datos desde diversas fuentes para garantizar su calidad y disponibilidad en arquitecturas modernas como los *Data Lakehouses*.

Flujo de Trabajo

1 Antes de la Clase (Fundamentación)

Preparación Individual

- [ ] **Lectura Conceptual:**
  - Conceptos de Ingeniería de Datos (IBM)
  - *Foco:* Diferencia entre un analista y un ingeniero de datos.
- [ ] **Exploración Técnica:**
  - Notebook: Carga de datos en formato Parquet
  - *Nota:* El formato Parquet es clave para la eficiencia en Big Data.

---

2 Durante la Clase (Agenda Técnica)

Temas Principales

1. Tipos y Fuentes de Datos

- **Estructurados:** (Tablas SQL)
- **Semiestructurados:** (JSON, XML, Parquet)
- **No estructurados:** (Imágenes, audios, PDFs)

2. El Pipeline de Ingeniería

- Ingestión y captura.
- Integración de múltiples fuentes.
- Calidad, consistencia y trazabilidad (Lineage).

3. Arquitecturas Modernas

- **Data Warehouse:** Datos limpios y estructurados.
- **Data Lake:** Almacenamiento masivo "crudo".
- **Lakehouse:** Lo mejor de ambos mundos (Fabric).

4. Gobernanza: Seguridad, ética y gobierno del dato.

🧪 **Laboratorios (Microsoft Fabric)**

Práctica en Nube

- **Laboratorio 1: SQL y Power BI**
  - Creación de entorno, tablas SQL y reportes interactivos.
  - 🔗 Guía Laboratorio 1
- **Laboratorio 2: Lakehouse y Análisis de Ventas**
  - Administración de Lakehouse y consultas visuales de ingresos.
  - 🔗 Guía Laboratorio 2

Presentaciones

- 📄 Introducción a la ingeniería de datos

3️⃣ Después de la Sesión (Taller de Integración)

Taller 2: Arquitectura de Datos

El objetivo es generar una **primera versión de alto nivel** de la arquitectura de tu proyecto.

Práctica sugerida (Merge):
Antes de diseñar la arquitectura, repasa cómo unir datasets:

- 🔗 Práctica Merge de datos 1
- 🔗 Práctica Merge de datos 2

✓ **Entrega**

- 📤 Taller 2. Comparte tu arquitectura de datos

📝 Glosario de Arquitectura

Término	Definición
Ingestión	El proceso de mover datos desde la fuente al destino.
ETL / ELT	Extract, Transform, Load (o viceversa).
Parquet	Formato de almacenamiento columnar que ahorra espacio y velocidad.
Merge	Operación de unión de tablas basada en una columna común (Join).