Feature engineering

Agenda

- ¿Porqué es necesario?
- Tareas comunes

Agenda

- ¿Porqué es necesario?
- Tareas comunes

Análisis y preparación

Análisis exploratorio

Estructura

Categóricas

Nulos y outliers

Distribución

Continuas

Nulos y outliers

Distribución

Correlación

Visualización

Feature engineering

Dummies

Normalización y estandarización

Feature selection

Modelo

Feature Engineering

el proceso de transformación de los datos para mejorar el rendimiento de un modelo de aprendizaje automático.

Assumptions of Linear Regression

1. Linearity
(Linear relationship between Y and each X)

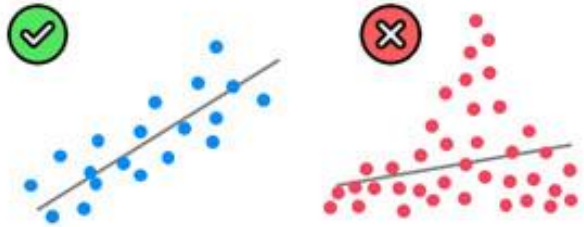

2. Homoscedasticity
(Equal variance)

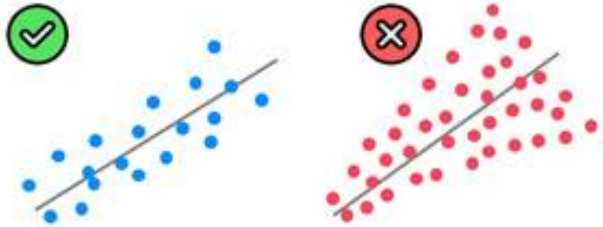

3. Multivariate Normality
(Normality of error distribution)

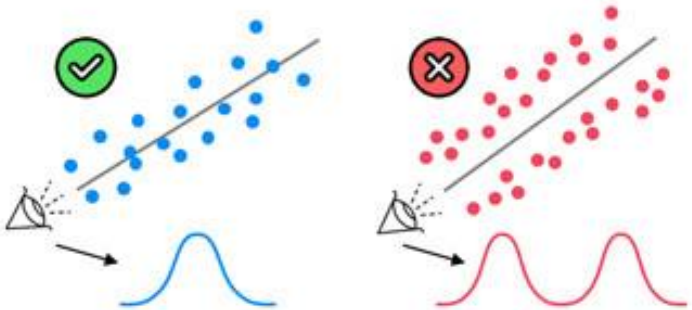

4. Independence
(of observations. Includes "no autocorrelation")

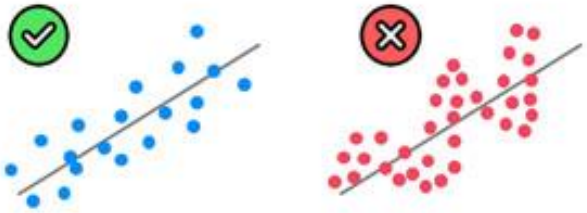

5. Lack of Multicollinearity
(Predictors are not correlated with each other)

$X_1 \nsim X_2$ $\quad$ $X_1 \sim X_2$

6. The Outlier Check
(This is not an assumption, but an "extra")

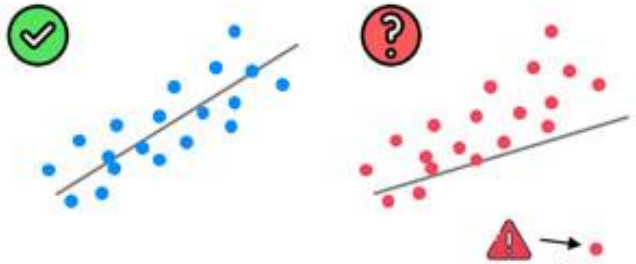

© SuperDataScience

“Coming up with features is difficult, time-consuming, requires expert knowledge. ‘Applied machine learning’ is basically feature engineering.”

Andrew Ng.

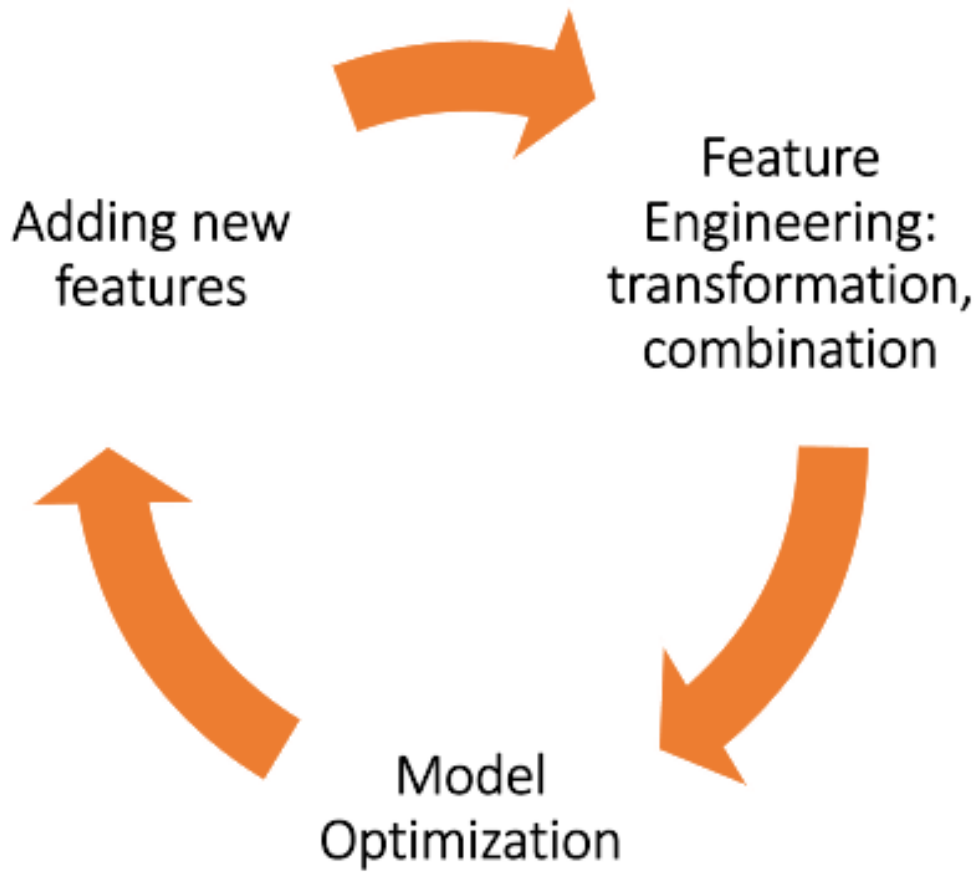

https://medium.com/@deeptij2007/feature-engineering-pipeline-for-production-ml-465721fcc3c2

Agenda

- ¿Porqué es necesario?
- Tareas comunes

Agenda

- ¿Porqué es necesario?
- Tareas comunes

Tareas comunes

Numerical

- Standardization

$$Z = \frac{X - \mu}{\sigma}$$

- Normalization

$$X_{normalized} = \frac{(X\ max - Xmin)}{(x_{minimum} - x_{minimum})}$$

- Bucketing

Age<18	19<=Age<30	30<=Age<40	Age>=40

Categorical

- One-hot encoding

Label Encoding

Food Name	Categorical #	Calories
Apple	1	95
Chicken	2	231
Broccoli	3	50

→

One Hot Encoding

Apple	Chicken	Broccoli	Calories
1	0	0	95
0	1	0	231
0	0	1	50

- TF-IDF

$$w_{i,j} = tf_{i,j} \times \log\left(\frac{N}{df_i}\right)$$

$tf_{i,j}$ = number of occurrences of i in j
df_i = number of documents containing i
N = total number of documents

- Word embeddings

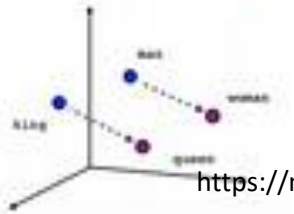

Dimensionality Reduction

- Principal component analysis (PCA)

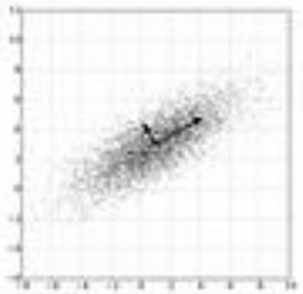

- t-SNE

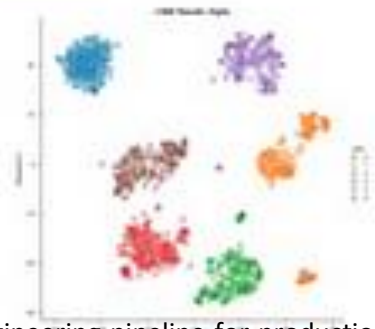

https://medium.com/@deeptij2007/feature-engineering-pipeline-for-production-ml-465721fcc3c2

Agenda

- ¿Porqué es necesario?
- Tareas comunes

Agenda

- ¿Porqué es necesario?
- Tareas comunes
  - Normalización y estandarización
  - One-hot /label enconding
  - Discretización
  - Creación de variables

Normalización

Precio casa = **m #Hab** + **m2** Mt2 + **m3** ValorInicial + **b**

Precio casa = **m1 #Hab[1 - 16]** + **m2** Mt2 **[10 - 100]** + **m3** ValorInicial **[1M – 1000M]** + **b**

Precio casa = **m1 #Hab[0- 1]** + **m2** Mt2 **[0- 1]** + **m3** ValorInicial **[0- 1]** + **b**

Precio casa = **m1 #Hab[0- 1]** + **m2** Mt2 **[0- 1]** + **m3** ValorInicial **[0- 1]** + **b**

Agenda

- ¿Porqué es necesario?
- Tareas comunes
  - Normalización y estandarización
  - One-hot /label enconding
  - Discretización
  - Creación de variables

Agenda

- ¿Porqué es necesario?
- Tareas comunes
  - Normalización y estandarización
  - One-hot /label enconding
  - Discretización
  - Creación de variables

Label encoding

Original Data

Team	Points
A	25
A	12
B	15
B	14
B	19
B	23
C	25
C	29

Label Encoded Data

Team	Points
0	25
0	12
1	15
1	14
1	19
1	23
2	25
2	29

Height
Tall
Medium
Short

Height
0
1
2

One-hot encoding

Original Data

Team	Points
A	25
A	12
B	15
B	14
B	19
B	23
C	25
C	29

One-Hot Encoded Data

Team_A	Team_B	Team_C	Points
1	0	0	25
1	0	0	12
0	1	0	15
0	1	0	14
0	1	0	19
0	1	0	23
0	0	1	25
0	0	1	29

Color
Red
Red
Yellow
Green
Yellow

Red	Yellow	Green
1	0	0
1	0	0
0	1	0
0	0	1

Dummy variable trap

Red
Blue
Green

Red	Blue	~~Green~~
1	0	~~0~~
0	1	~~0~~
0	0	~~1~~

One-Hot encoding cuando:

- La característica categórica no es ordinal (e.g. países)
- La cantidad de características categóricas es baja

Label-encoding cuando:

- La característica categórica es ordinal (como Jr. kg, Sr. kg, escuela primaria, escuela secundaria)
- El número de categorías es bastante grande, ya que la codificación one-hot puede provocar un alto consumo de memoria.

One hot encoding (multiple categories)

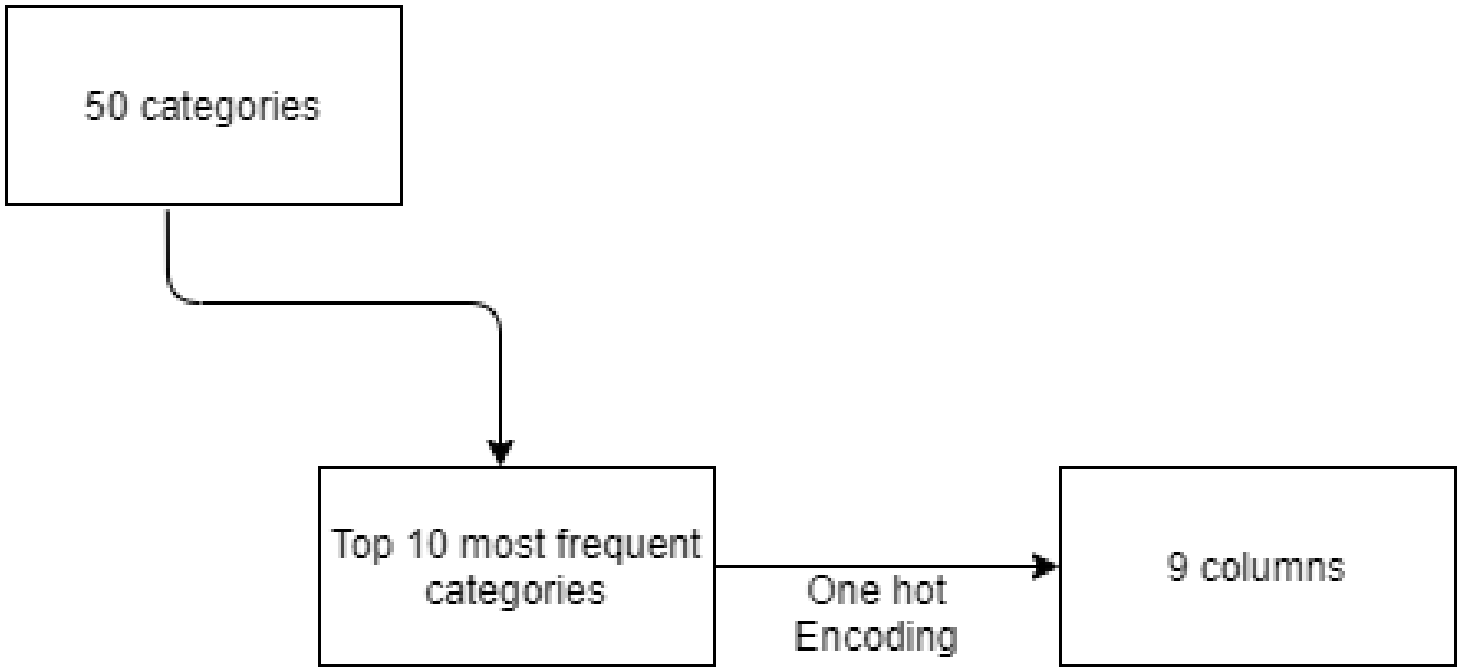

Agenda

- ¿Porqué es necesario?
- Tareas comunes
  - Normalización y estandarización
  - One-hot /label enconding
  - Discretización
  - Creación de variables

Agenda

- ¿Porqué es necesario?
- Tareas comunes
  - Normalización y estandarización
  - One-hot /label enconding
  - Discretización
  - Creación de variables

Discretización

Técnica de preprocesamiento que permite agrupar números de valores más o menos continuados en un número más reducido de “contenedores”. Por ejemplo, es posible que desee ordenar las edades en intervalos de edad menores (por ejemplo, agrupar las edades por intervalos de cinco años).

https://aws.amazon.com/es/about-aws/whats-new/2021/03/aws-glue-databrew-adds-binning-skewness-binarization-transformations-pre-processing-data

Discretización

- Algoritmos supervisados (usan la etiqueta de clase):
  - Basado en entropía [Fayyad & Irani 93 y otros]
  - Binning [Holte 93]

- Algoritmos no supervisados:
  - Intervalos de igual ancho
  - Intervalos de frecuencia iguales

Ventajas

- Algunos algoritmos se limitan a entradas discretas.
- Muchos algoritmos discretizan como parte del algoritmo de aprendizaje (árbol de decisiones)
- Eficiencia. Las funciones continuas ralentizan drásticamente los algoritmos de aprendizaje

Discretización con arboles de decisión

4 bins for max_depth=2

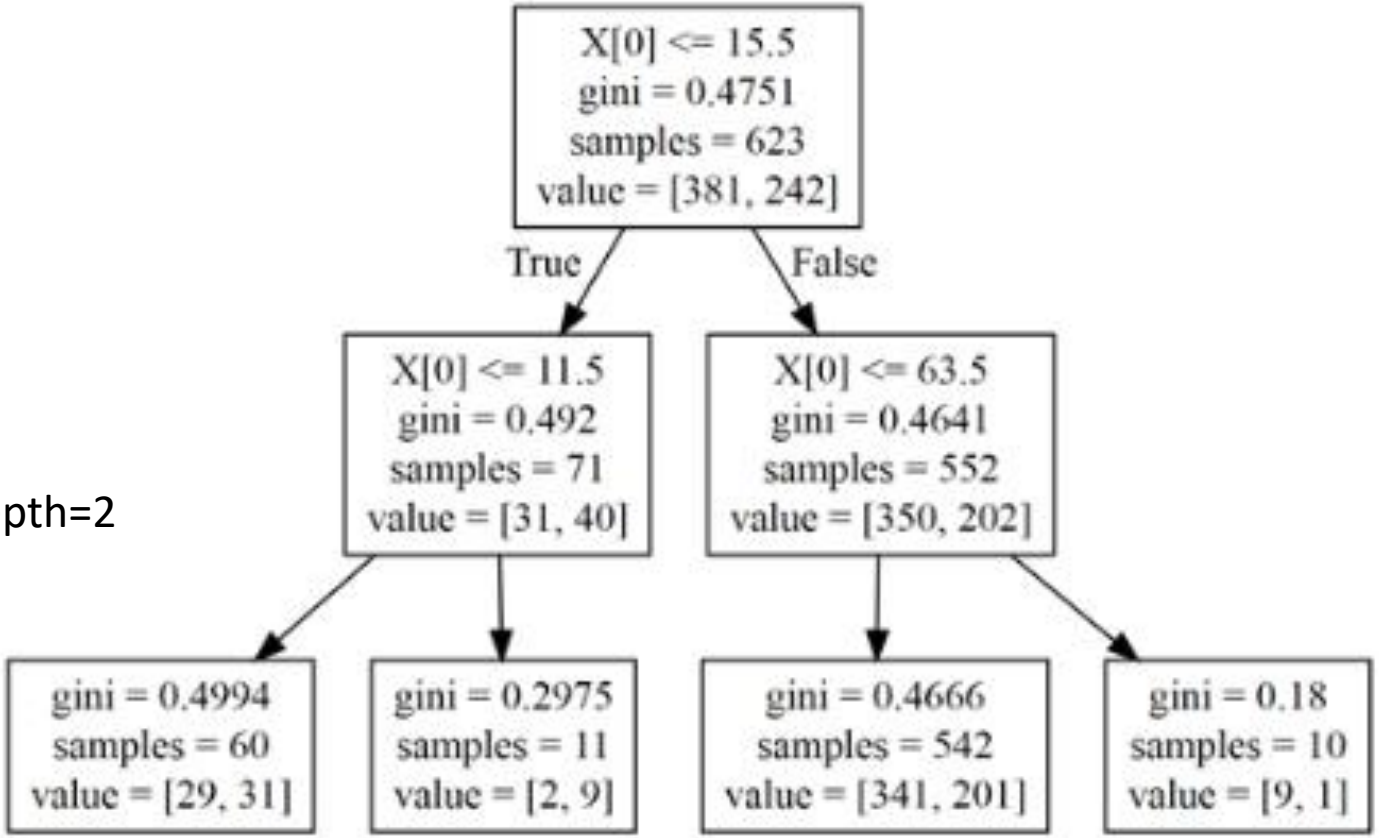

https://towardsdatascience.com/discretisation-using-decision-trees-21910483fa4b

Agenda

- ¿Porqué es necesario?
- Tareas comunes
  - Normalización y estandarización
  - One-hot /label enconding
  - Discretización
  - Creación de variables

Agenda

- ¿Porqué es necesario?
- Tareas comunes
  - Normalización y estandarización
  - One-hot /label enconding
  - Discretización
  - Creación de variables

Ejemplo

	Sabor	Fecha y Hora	Dia	Longitud	Amplitud	Precio
0	Chocolate Hearts	2020-02-09 14:05:00	Sunday	3.0	2.0	7.5
1	Sour Jelly	2020-10-24 18:00:00	Saturday	3.5	2.0	7.6
2	Candy Canes	2020-12-18 20:13:00	Friday	3.5	2.5	8.0
3	Sour Jelly	2020-10-25 10:00:00	Sunday	3.5	2.0	7.6
4	Fruit Drops	2020-10-18 15:46:00	Sunday	5.0	3.0	9.0

https://www.projectpro.io/article/8-feature-engineering-techniques-for-machine-learning/423

Centrándose en la fecha

	Sabor	Fecha
0	Chocolate Hearts	2020-02-09
1	Sour Jelly	2020-10-24
2	Candy Canes	2020-12-18
3	Sour Jelly	2020-10-25
4	Fruit Drops	2020-10-18

https://www.projectpro.io/article/8-feature-engineering-techniques-for-machine-learning/423

Si es fin de semana

	Sabor	Fecha	Fin Semana
0	Chocolate Hearts	2020-02-09	1
1	Sour Jelly	2020-10-24	1
2	Candy Canes	2020-12-18	0
3	Sour Jelly	2020-10-25	1
4	Fruit Drops	2020-10-18	1

Nueva

https://www.projectpro.io/article/8-feature-engineering-techniques-for-machine-learning/423

1. Generación de Variables Temporales

- **Caso**: Predecir la demanda de bicicletas.

- Extraer características como:
- Hora del día
- Día de la semana
- Mes
- Temporada

- **Mejora**: Captura patrones temporales que afectan la demanda.

2. Combinación de Características

- Caso: Predicción de precios de casas.

- Crear características como:
- Densidad Habitacional = Habitantes / Área
- Edad de la casa por tamaño = Edad / Tamaño

- Mejora: Identifica factores combinados que influyen en los precios.

3. Relaciones no Lineales

- **Caso**: Predicción del riesgo crediticio.

- Transformar características:
- Log(Ingresos)
- Log(Edad)

- Crear interacciones:
- Ingresos por Edad = Ingresos / Edad

- **Mejora**: Captura relaciones complejas y no evidentes.

4. Características Binarias

- **Caso**: Predicción de conversión en un sitio web.

- Crear variables como:
  - Nuevo Usuario (tiempo desde última visita)
  - Tiempo en sitio categorizado (quintiles).

- **Mejora**: Captura comportamientos específicos de usuarios.

In God We Trust!