8. Sesión 5 - Preparación de Datos y Construcción de Pipelines

Objetivo de la Sesión

Pasar de la limpieza manual a la **automatización robusta**. El foco es estructurar transformaciones (escalado, codificación e ingeniería de variables) mediante **Pipelines** para garantizar que el modelo sea reproducible y esté libre de **Data Leakage**.

Plan de Trabajo

1 Antes de la Clase: Fundamentos Prácticos

Laboratorios de Preparación (GitHub)

- [ ] **Impacto de Encoding:** Comparar *One Hot Encoding* vs. *Label Encoding* y su efecto en la dimensionalidad.
- [ ] **Normalización:** Practicar técnicas de Estandarización (Z-score) y Normalización (Min-Max).
- [ ] **Selección de Variables:** Identificar las características con mayor poder predictivo.
  - Notebook: Práctica Selección de Variables
- [ ] **Caso de Estudio:** Aplicar lo anterior en el dataset de *Loan Prediction*.

2 Durante la Clase: Agenda Técnica

Conceptos de Nivel Avanzado

1. Seguimiento de Proyectos: Revisión de dudas en la aplicación de técnicas a los datasets individuales.

2. Data Leakage (Fuga de Datos): Identificar cuándo el modelo "hace trampa" al ver datos del set de prueba durante el entrenamiento.

3. Pipelines & Custom Transformers:

- Uso de `Pipeline` de Scikit-Learn para encadenar pasos.
- Creación de clases personalizadas para transformaciones específicas del negocio. **4. Feature Engineering:** Creación de nuevas variables que aporten valor al modelo.

🧪 Recursos y Laboratorios

🏗️ Arquitectura de Pipelines

- 🔗 Laboratorio: Construcción de Pipelines - Parte 1
- 🔗 Laboratorio: Construcción de Pipelines - Parte 2
- 🧪 Implementación: Pipeline para Regresión Lineal

⚙️ Transformaciones Específicas

- 📊 Estandarización y Normalización
- 🏷️ Impacto de One Hot vs Label Encoding
- 🛡️ Laboratorio: Detección de Data Leakage

🎥 Entregable: Taller 3 y Video de Preparación

🔥 Hito de Evaluación

Debes entregar la preparación completa de tu dataset junto con un video explicativo (5-10 min).

Puntos clave para el video:

1. **Definición:** Problema y pregunta **SMART**.
2. **Pipeline:** Mostrar el código del flujo automatizado y transformadores personalizados.
3. **Insights:** Hallazgos más relevantes tras preparar los datos.
4. **Validación:** Entrenamiento de un modelo básico para verificar que los datos están listos.

📝 Resumen Técnico para PDF

Técnica	Cuándo usarla	Evita...
One Hot Encoding	Variables nominales sin orden (Categorías independientes).	Sesgo de orden inexistente.
StandardScaler	Variables con distribución normal o algoritmos basados en distancia (KNN, SVM).	Que variables grandes dominen a las pequeñas.
Pipelines	En todos los proyectos de producción.	Errores manuales y Data Leakage.
Custom Transformers	Cuando necesitas lógica de limpieza muy específica (ej. limpiar texto).	Código desorganizado y repetitivo.

> ✓ **Enlace de Entrega**
>
> 📤 **Taller 3. Comparte la preparación de los datos**

Tip de exportación: Si usas el tema por defecto de Obsidian, este formato de tablas y callouts se mantiene limpio en el PDF, ideal para presentarlo como parte de tu documentación de maestría.