MICE

Multiple Imputations by Chained Equations

1. Toma la variable con valores faltantes como respuesta 'Y'
2. Las otras variables son predictores 'X'
3. Construye un modelo entrenándose con las filas que tienen el valor de 'Y'.
4. Predice las observaciones faltantes.

1. Decida el número de iteraciones (k)

2. En cada columna, reemplace los valores que faltan con un valor aproximado como la "media". Este es un reemplazo temporal.

3. Para la columna que desea imputar (e.g. A) se cambia el valor imputado a FALTANTE

4. Construya un modelo para predecir A usando (B y C) como predictores. Se entrena con las filas de A que no faltan.

5. Utilice este modelo para predecir los valores faltantes en A.

5. Repita los pasos 2 a 4 también para las columnas B y C.

Missing data is in red. There is a strong correlation between A and B, so let's try to impute A using B and C.

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
	0.80	
0.95	1.24	1.46
0.23	0.57	
0.90		1.28
0.15	0.42	
0.47	0.54	0.63
	1.14	
0.89	1.23	1.45

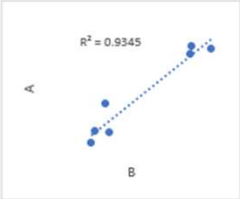

Missing data is filled in randomly. This dillutes the correlations, but allows us to impute using all available data.

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.90	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	0.46	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.47	1.14	1.28
0.89	1.23	1.45

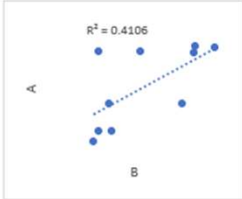

A random forest is used to predict A with B and C. Notice the correlation between A and B improved.

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.24	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	0.46	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.89	1.14	1.28
0.89	1.23	1.45

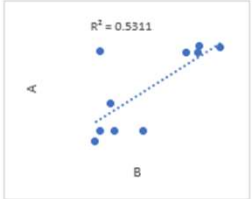

After Imputing B using A and C, we have achieved a correlation between A and B much closer to the original data.

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.24	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	1.24	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.89	1.14	1.28
0.89	1.23	1.45

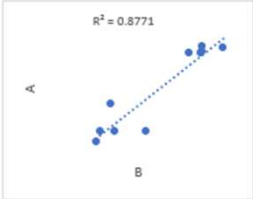

https://cran.r-project.org/web/packages/miceRanger/vignettes/miceAlgorithm.html

- https://scikit-learn.org/stable/modules/impute.html

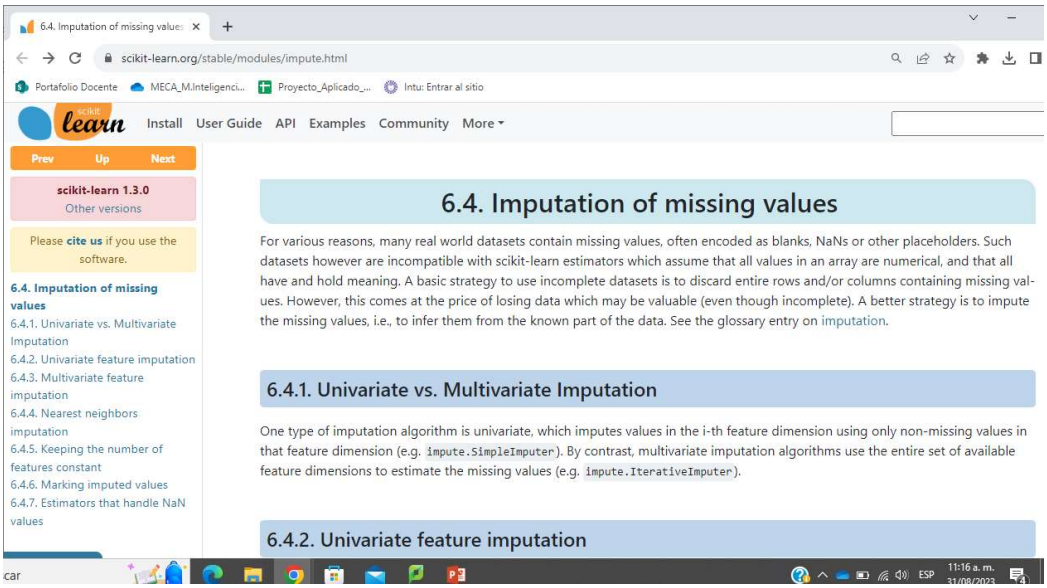

imputation based on clustering

Assigns observations to clusters and fill in cluster means for missing observations.

K-Means Clustering Imputation (KMI)

1. Los datos se dividen en k grupos.
2. El centroide de cada grupo se calcula los valores medios de los elementos del grupo.
3. Los datos se dividen en dos partes: una con datos completos y otra con faltantes.
4. Se agregan los datos con valores faltantes a un grupo.
5. Para imputación se puede elegir media, valor mas cercano, etc.