5. Unidad 5 - Algoritmo K-Nearest Neighbors (KNN)

El Algoritmo de la Intuición

El algoritmo **K-Nearest Neighbors (KNN)** es uno de los métodos más intuitivos y poderosos del aprendizaje supervisado. Se basa en una premisa simple: "dime quiénes son tus vecinos y te diré quién eres". Se utiliza tanto para **clasificación** (predecir una etiqueta) como para **regresión** (predecir un valor numérico).

🔍 ¿Cómo funciona KNN?

KNN no "aprende" un modelo matemático complejo; en su lugar, memoriza los datos de entrenamiento y toma decisiones basadas en la proximidad.

El Proceso Paso a Paso:

1. **Recibir** un nuevo dato sin etiquetar.
2. **Calcular la distancia** entre ese nuevo dato y todos los puntos que ya conoce (el conjunto de entrenamiento).
3. **Seleccionar los K vecinos** más cercanos (donde K es un número entero definido por el usuario).
4. **Decidir:**
   - **En Clasificación:** Vota por la clase más común entre los vecinos.
   - **En Regresión:** Calcula el promedio de los valores de los vecinos.

🛠️ Aplicaciones Prácticas

- ✍️ **Reconocimiento de Patrones:** Clasificación de dígitos escritos a mano (MNIST) comparando trazos similares.
- 🎬 **Sistemas de Recomendación:** Sugerir películas o productos basados en usuarios con perfiles de consumo "cercanos".

- 🩺 **Diagnóstico Médico:** Comparar síntomas de un nuevo paciente con casos históricos para sugerir diagnósticos.
- 🚫 **Detección de Fraude:** Identificar transacciones anómalas por su lejanía de los patrones de comportamiento normales.

📅 Plan de Trabajo - Sesión 11

1️⃣ Antes de la Clase (Preparación)

📝 Lecturas Obligatorias

- [ ] **Conceptos Base:** ¿Qué es KNN?
- [ ] **Documentación Técnica:** Scikit-learn: Neighbors
- [ ] **Teoría de Distancias:** Measures of Similarity and Dissimilarity
    - *Foco:* Entender la diferencia entre Distancia Euclidiana, Manhattan y Minkowski.

2️⃣ Durante la Clase (Práctica)

📝 Recursos Disponibles

- 📁 Notebooks_S11 | 📂 Data_S11

🏁 Sesión 12: Evaluación Final

🔥 Hito del Curso

La Sesión 12 está reservada para la **Evaluación Final** de la unidad y/o del curso. Asegúrate de haber repasado:

1. Cómo elegir el valor óptimo de K (el dilema del sesgo y la varianza).
2. La importancia de **escalar los datos** (Normalización/Estandarización) antes de usar KNN.

3. El impacto de las diferentes métricas de distancia en el resultado final.

📝 Notas de Implementación (Python)

```python
from sklearn.neighbors import KNeighborsClassifier
from sklearn.preprocessing import StandardScaler

# IMPORTANTE: KNN requiere escalado de datos porque se basa en distancias
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)

# Definir el modelo (K=5 es el estándar por defecto)
model = KNeighborsClassifier(n_neighbors=5, metric='euclidean')
model.fit(X_train_scaled, y_train)
```