7. Sesión 4 - Análisis Exploratorio y Preparación de Datos

Objetivo de la Unidad

Al finalizar esta unidad, serás capaz de describir las características principales de un conjunto de datos empleando estadísticas descriptivas y técnicas de visualización avanzadas. El EDA es el pilar de CRISP-DM para garantizar la calidad del modelo final.

Flujo de Trabajo

1 Antes de la Clase (Fundamentos)

Preparación Técnica

- [ ] **Lectura Académica:** Páginas 12 a 18 del libro guía sobre conceptos fundamentales de EDA. Abrir Libro PDF
- [ ] **Exploración de Visualización:** Revisar tipos de gráficos en Python para representar datos de forma persuasiva. Python Charts Guide
- [ ] **Pre-Laboratorios (Impacto):**
  - Outliers
  - Impacto de Datos Nulos en el Rendimiento
  - Imputación y Modelado
  - Imputación por MICE (Multivariate Imputation by Chained Equations)

2 Durante la Clase (Agenda de Sesión)

Contenido Magistral

1. Seguimiento de Proyectos: Revisión del progreso individual y feedback constructivo.
2. Flujo de EDA y Preparación: Importancia de los tipos de datos, manejo de faltantes y detección de valores atípicos.

3. Técnicas Multivariadas: Correlación profunda, nulos y detección de outliers con enfoques multivariados.

📄 **Presentaciones y Slides**

- Análisis exploratorio de datos
- Valores perdidos (Missing Data)
- Outliers (Atípicos)
- MICE y Clustering

🧪 **Laboratorios Sincrónicos**

- 🧹 Laboratorio: Limpieza de Datos
- 📈 Histogramas y Gráficos de Densidad
- 📊 Visualización Univariada
- 💳 Predicción de Préstamos (Loan Prediction)

3️⃣ Después de la Sesión (Profundización y Taller)

🔥 Taller Práctico: Salud

Realiza un **Análisis Univariado y Multivariado** del dataset de salud proporcionado. La solución se revisará en la siguiente sesión.
🔗 Acceder al Taller Salud

📝 Recursos de Refuerzo

- [ ] **KDE (Kernel Density Estimation):** Entender la estimación de densidad no paramétrica. 🔗 Ver Artículo Interactivo
- [ ] **Asimetría (Skewness) y Curtosis:** Clave para identificar la forma de la distribución y posibles outliers. 🔗 Guía de Analytics Vidhya
- [ ] **EDA Categórico:** Revisar notebook sobre manejo de variables cualitativas. 🔗 GitHub Repository

---

📝 Conceptos Críticos para el PDF

Análisis Exploratorio de Datos (EDA)

- **Univariado:** Análisis de una sola variable (distribución, tendencia central, dispersión).
- **Bivariado:** Relación entre dos variables (correlación, dispersión, tablas de contingencia).
- **Multivariado:** Interacciones complejas entre múltiples variables (MICE, Clustering).

Tratamiento de Datos "Sucios"

Problema	Técnica Común
Outliers	Z-Score, Rango Intercuartílico (IQR), Aislamiento de Bosques.
Nulos (MCAR/MAR)	Imputación simple (Media/Mediana) o avanzada (MICE).
Sesgo (Skewness)	Transformaciones logarítmicas o Box-Cox.