Universidad ICESI

45 años

Introducción a los datos

Fuentes y almacenes

José Armando Ordóñez

Objetivos

Conocer los conceptos básicos de los datos, fuentes, tipos y almacenes

Agenda

- Tipos de datos
- Almacenes de datos
- Arquitectura medallón

Agenda

- Tipos de datos
- Almacenes de datos
- Arquitectura medallón

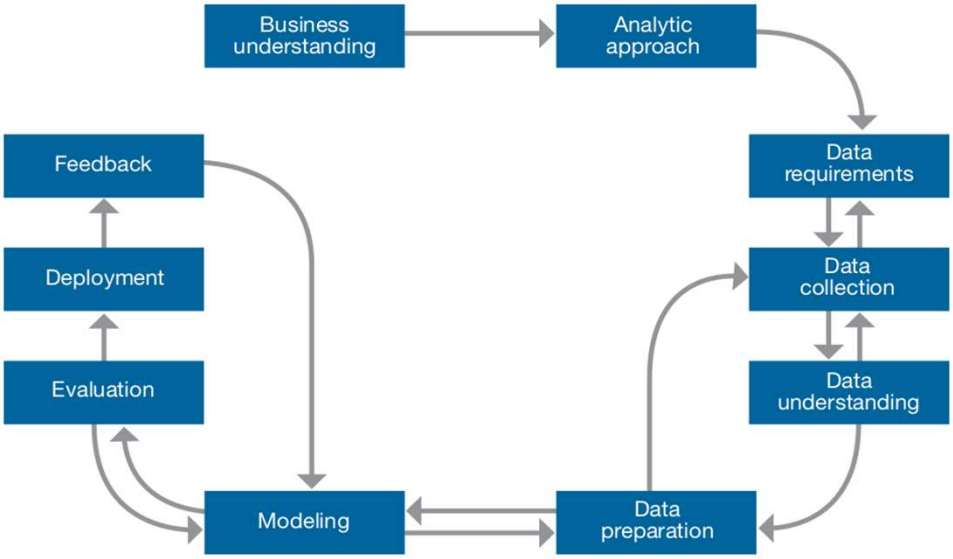

Fuente: Foundational methodology for Data Science. White paper. IBM, 2015

CustomerID	Title	FirstName	MiddleName	LastName	Suffix	CompanyName	Phone
1	Mr.	Orlando	N.	Gee	NULL	A Bike Store	245-555-0173
2	Mr.	Keith	NULL	Harris	NULL	Progressive Sports	170-555-0127
3	Ms.	Donna	F.	Carreras	NULL	Advanced Bike Components	279-555-0130
4	Ms.	Janet	M.	Gates	NULL	Modular Cycle Systems	710-555-0173
5	Mr.	Lucy	NULL	Harrington	NULL	Metropolitan Sports Supply	828-555-0186
6	Ms.	Rosmarie	J.	Carroll	NULL	Aerobic Exercise Company	244-555-0112
7	Mr.	Dominic	P.	Gash	NULL	Associated Bikes	192-555-0173
10	Ms.	Kathleen	M.	Garza	NULL	Rural Cycle Emporium	150-555-0127
11	Ms.	Katherine	NULL	Harding	NULL	Sharp Bikes	926-555-0159
12	Mr.	Johnny	A.	Caprio	Jr.	Bikes and Motorbikes	112-555-0191
16	Mr.	Christopher	R.	Beck	Jr.	Bulk Discount Store	1 (11) 500 555-0132
18	Mr.	David	J.	Liu	NULL	Catalog Store	440-555-0132
19	Mr.	John	A.	Beaver	NULL	Center Cycle Shop	521-555-0195
20	Ms.	Jean	P.	Handley	NULL	Central Discount Store	582-555-0113
21	N...	Jinghao	NULL	Liu	NULL	Chic Department Stores	928-555-0116
22	Ms.	Linda	E.	Burnett	NULL	Travel Systems	121-555-0121
23	Mr.	Kerim	NULL	Hanif	NULL	Bike World	216-555-0122
24	Mr.	Kevin	NULL	Liu	NULL	Eastside Department Store	926-555-0164
25	Mr.	Donald	L.	Blanton	NULL	Coalition Bike Company	357-555-0161
28	Ms.	Jackie	E.	Blackwell	NULL	Commuter Bicycle Store	972-555-0163
29	Mr.	Bryan	NULL	Hamilton	NULL	Cross-Country Riding Supp...	344-555-0144
30	Mr.	Todd	R.	Logan	NULL	Cycle Merchants	783-555-0110
34	Ms.	Barbara	J.	German	NULL	Cycles Wholesaler & Mfg.	1 (11) 500 555-0181
37	Mr.	Jim	NULL	Geist	NULL	Two Bike Shops	724-555-0161

Datos estructurados

ProductID	Name	ProductNumber	Color	StandardCost	ListPrice	Size	Weight
680	HL Road Frame - Black, 58	FR-R92B-58	Black	1059.31	1431.50	58	1016.04
706	HL Road Frame - Red, 58	FR-R92R-58	Red	1059.31	1431.50	58	1016.04
707	Sport-100 Helmet, Red	HL-U509-R	Red	13.0863	34.99	NULL	NULL
708	Sport-100 Helmet, Black	HL-U509	Black	13.0863	34.99	NULL	NULL
709	Mountain Bike Socks, M	SO-B909-M	White	3.3963	9.50	M	NULL
710	Mountain Bike Socks, L	SO-B909-L	White	3.3963	9.50	L	NULL
711	Sport-100 Helmet, Blue	HL-U509-B	Blue	13.0863	34.99	NULL	NULL
712	AWC Logo Cap	CA-1098	Multi	6.9223	8.99	NULL	NULL
713	Long-Sleeve Logo Jersey, S	LJ-0192-S	Multi	38.4923	49.99	S	NULL
714	Long-Sleeve Logo Jersey, M	LJ-0192-M	Multi	38.4923	49.99	M	NULL
715	Long-Sleeve Logo Jersey, L	LJ-0192-L	Multi	38.4923	49.99	L	NULL
716	Long-Sleeve Logo Jersey, XL	LJ-0192-X	Multi	38.4923	49.99	XL	NULL
717	HL Road Frame - Red, 62	FR-R92R-62	Red	868.6342	1431.50	62	1043.26
718	HL Road Frame - Red, 44	FR-R92R-44	Red	868.6342	1431.50	44	961.61
719	HL Road Frame - Red, 48	FR-R92R-48	Red	868.6342	1431.50	48	979.75
720	HL Road Frame - Red, 52	FR-R92R-52	Red	868.6342	1431.50	52	997.90
721	HL Road Frame - Red, 56	FR-R92R-56	Red	868.6342	1431.50	56	1016.04
722	LL Road Frame - Black, 58	FR-R38B-58	Black	204.6251	337.22	58	1115.83
723	LL Road Frame - Black, 60	FR-R38B-60	Black	204.6251	337.22	60	1124.90
724	LL Road Frame - Black, 62	FR-R38B-62	Black	204.6251	337.22	62	1133.98
725	LL Road Frame - Red, 44	FR-R38R-44	Red	187.1571	337.22	44	1052.33
726	LL Road Frame - Red, 48	FR-R38R-48	Red	187.1571	337.22	48	1070.47
727	LL Road Frame - Red, 52	FR-R38R-52	Red	187.1571	337.22	52	1088.62

```
// Customer 1
{
  "firstName": "Joe",
  "lastName": "Jones",
  "address":
  {
    "streetAddress": "1 Main St.",
    "city": "New York",
    "state": "NY",
    "postalCode": "10099"
  },
  "contact":
  [
    {
      "type": "home",
      "number": "555 123-1234"
    },
    {
      "type": "email",
      "address": "joe@litware.com"
    }
  ]
}
```

```
// Customer 2
{
  "firstName": "Samir",
  "lastName": "Nadoy",
  "address":
  {
    "streetAddress": "123 Elm Pl.",
    "unit": "500",
    "city": "Seattle",
    "state": "WA",
    "postalCode": "98999"
  },
  "contact":
  [
    {
      "type": "email",
      "address": "samir@northwind.com"
    }
  ]
}
```

Datos semiestructurados

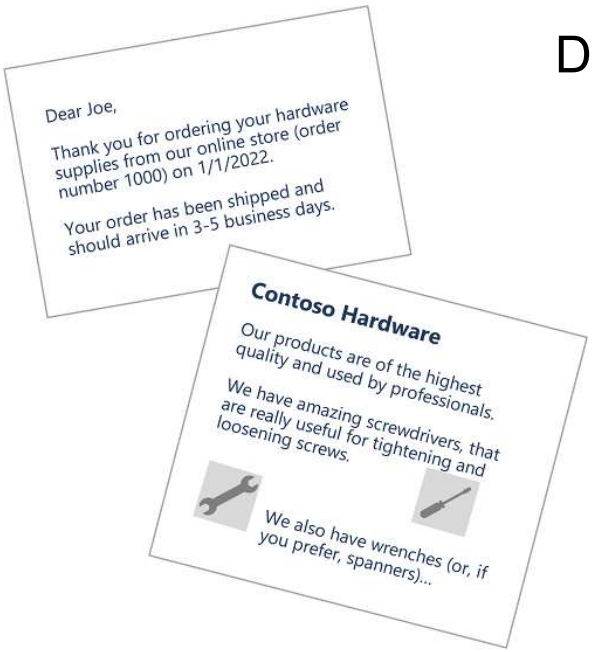

Datos no estructurados

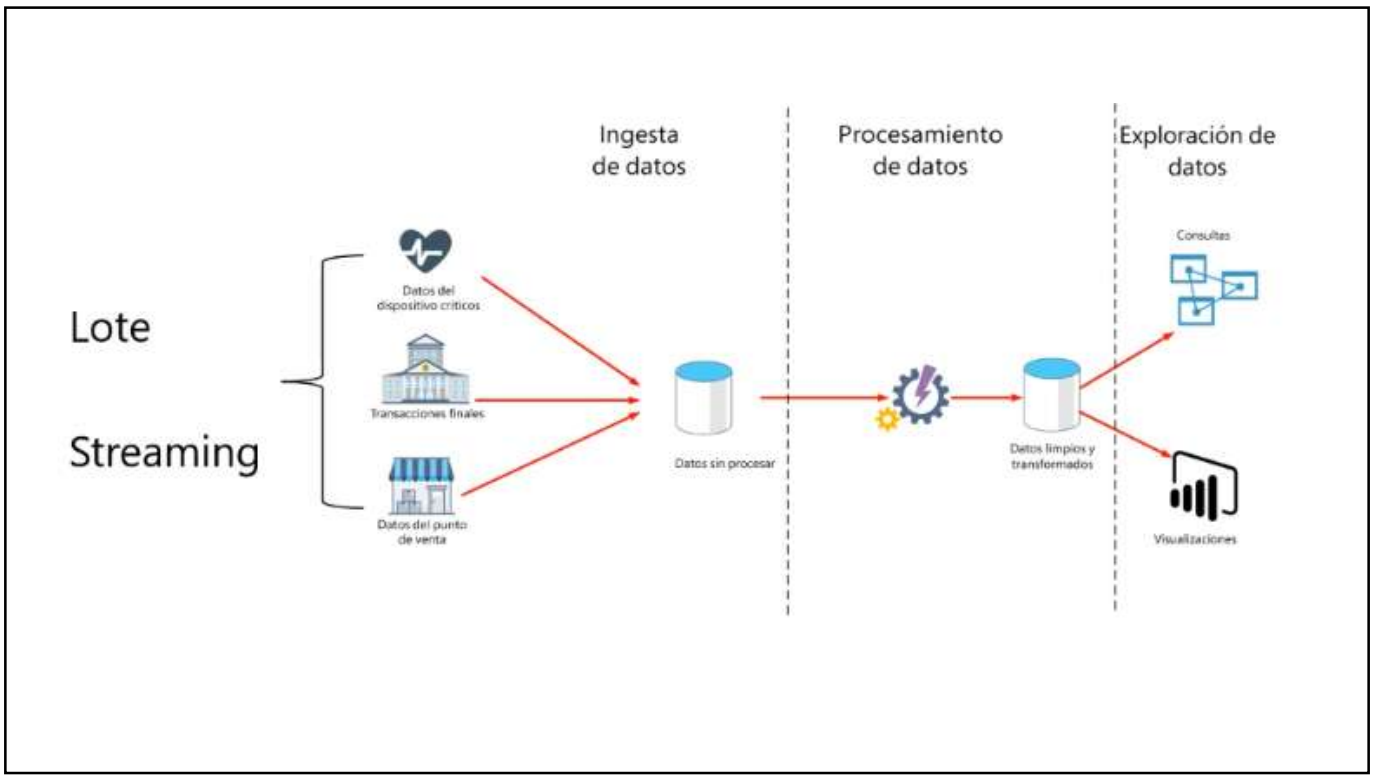
Ingesta de datos
Procesamiento de datos
Exploración de datos
Lote
Streaming
Datos del dispositivo críticos
Transacciones finales
Datos del punto de venta
Datos sin procesar
Datos limpios y transformados
Consultas
Visualizaciones

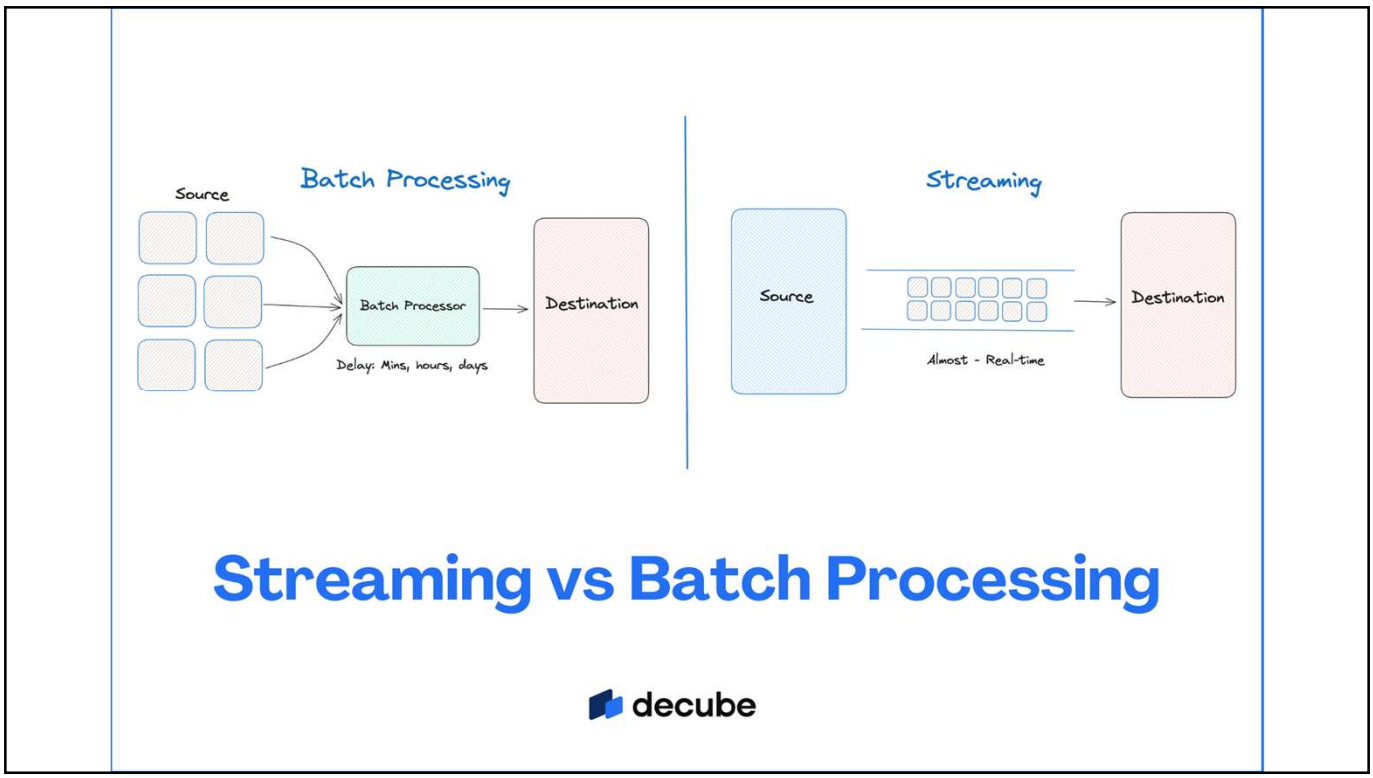
Batch Processing
Source
Batch Processor
Destination
Delay: Mins, hours, days
Streaming
Source
Destination
Almost - Real-time
Streaming vs Batch Processing
decube

Agenda

- Tipos de datos
- Almacenes de datos
- Arquitectura medallón

Agenda

- Tipos de datos
- Almacenes de datos
- Arquitectura medallón

Almacenes de datos

- Almacenes de archivos
- Bases de datos
- OLTP vs OLAP

Almacenes de datos

- Almacenes de archivos
- Bases de datos
- OLTP vs OLAP

Almacenamiento de archivos

- El formato de archivo depende de :
  - El tipo de datos (estructurados, semiestructurados o no estructurados).
  - Las aplicaciones y los servicios que tendrán que leer, escribir y procesar los datos.
  - La necesidad de que los archivos de datos **sean legibles** para los usuarios o estén optimizados para un **almacenamiento y procesamiento** eficientes.

Formatos de archivo optimizados

- Los formatos legibles no están optimizados para el procesamiento ni almacenamiento.
- Algunos formatos permiten la compresión, la indexación y almacenamiento y procesamiento eficientes:
  - *Avro*
  - *ORC*
  - *Parquet*

Almacenes de datos

- Almacenes de archivos
- Bases de datos
- OLTP vs OLAP

Almacenes de datos

- Almacenes de archivos
- Bases de datos
- OLTP vs OLAP

Bases de datos relacionales

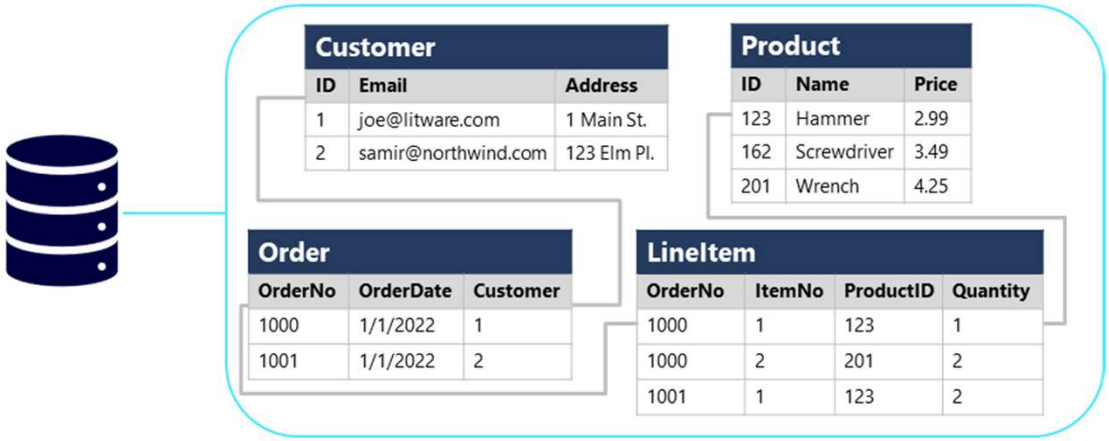

Customer

ID	Email	Address
1	joe@litware.com	1 Main St.
2	samir@northwind.com	123 Elm Pl.

Product

ID	Name	Price
123	Hammer	2.99
162	Screwdriver	3.49
201	Wrench	4.25

Order

OrderNo	OrderDate	Customer
1000	1/1/2022	1
1001	1/1/2022	2

LineItem

OrderNo	ItemNo	ProductID	Quantity
1000	1	123	1
1000	2	201	2
1001	1	123	2

Bases de datos no relacionales

- No aplican un esquema relacional se conocen como NoSQL.
- Hay 4 tipos

Bases de datos de clave-valor

Cada registro tiene una clave única y un valor asociado en cualquier formato.

Products	
Key	**Value**
123	"Hammer ($2.99)"
162	"Screwdriver ($3.49)"
201	"Wrench ($4.25)"

Bases de datos de documentos

El valor es un documento **JSON**

Customers	
Key	**Document**
1	{ "name": "Joe Jones", "email": "joe@litware.com" }
2	{ "name": "Samir Nadoy", "email": "Samir@northwind.com" }

Bases de datos de familia de columnas

Ofrecen la posibilidad de dividir las columnas en grupos (familias de columnas) con una relación lógica entre sí.

Orders				
Key	Customer		Product	
	Name	Address	Name	Price
1000	Joe Jones	1 Main St.	Hammer	2.99
1001	Samir Nadoy	123 Elm Pl.	Wrench	4.25

Bases de datos de grafos

Almacenan entidades como nodos con vínculos para definir relaciones entre ellas.

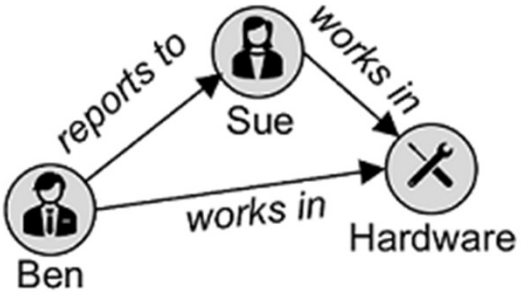

Almacenes de datos

- Almacenes de archivos
- Bases de datos
- OLTP vs OLAP

Almacenes de datos

- Almacenes de archivos
- Bases de datos
- OLTP vs OLAP

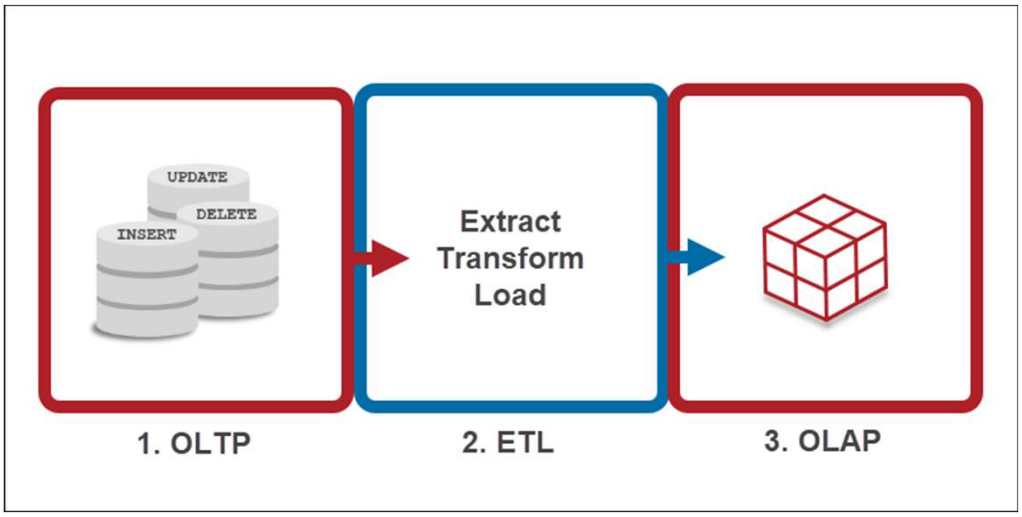

https://phoenixnap.com

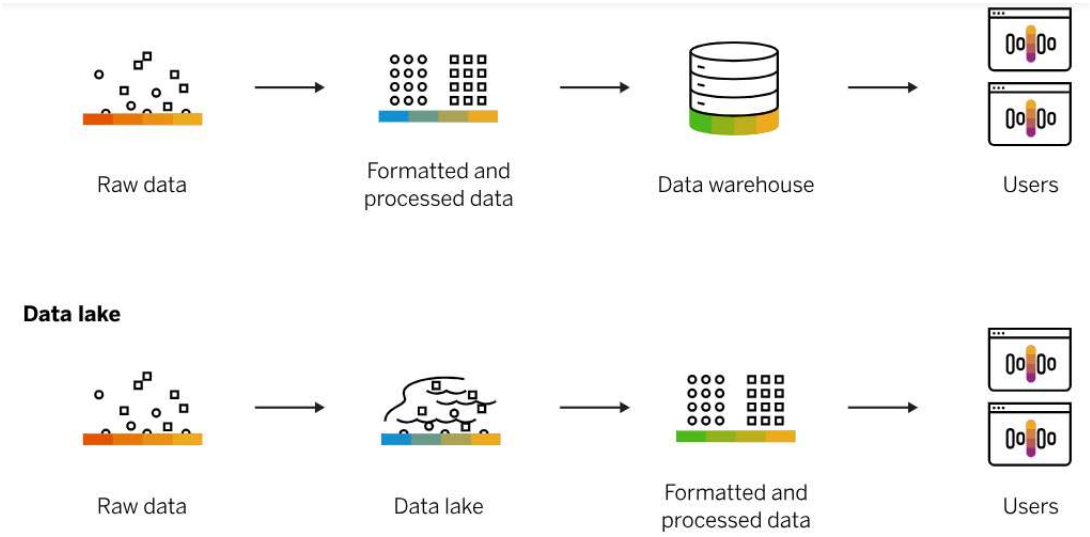

https://www.sap.com/uk/products/technology-platform/hana/what-is-a-data-lake.html

ETL (Extract, transform, load)

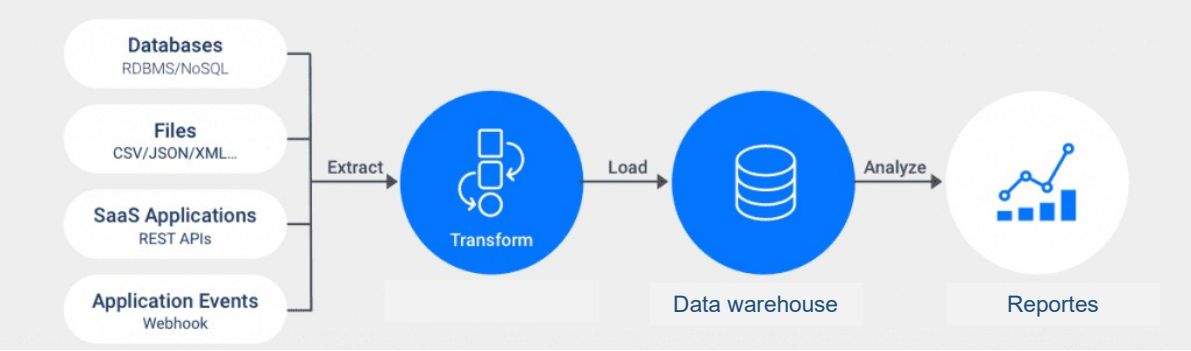

29

ETL (Extract, load, transform)

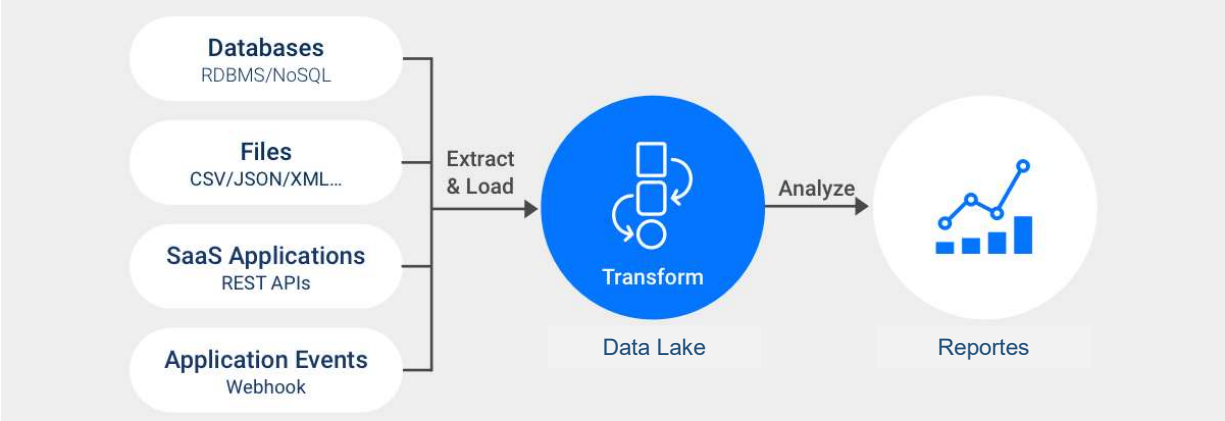

30

Data Lake

Se almacena toda la información **independientemente de la fuente y su estructura.**

Funciona como un **"repositorio"** de datos estructurados, semi-estructurados y no-estructurados.

Se define el esquema de la data **después** de su almacenamiento, al momento de ser usada.

Usa el proceso **extracción-carga-transformación.**

Ideal para hacer **todo tipo de análisis en profundidad.**

Data Warehouse

Se almacena información, proveniente de sistemas transaccionales, **que pasa por un proceso de normalización y transformación.**

Se **combinan tecnologías** para recopilar y gestionar datos procedentes de distintas fuentes (suelen almacenarse de manera estructurada).

Se define el esquema **antes** del almacenamiento y **antes** de su uso.

Usa el proceso **extracción-transformación-carga.**

Ideal para **usuarios operacionales.**

https://www.7puentes.com

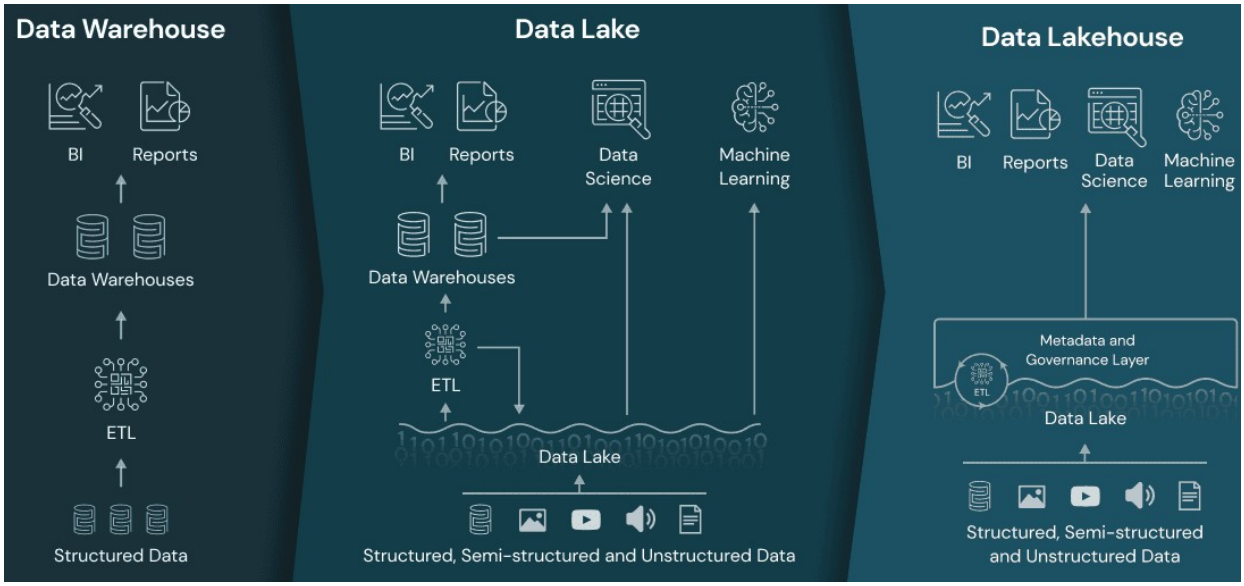

Agenda

- Tipos de datos
- Almacenes de datos
- Arquitectura medallón

Agenda

- Tipos de datos
- Almacenes de datos
- Arquitectura medallón

No
Estructurado
Estructurado

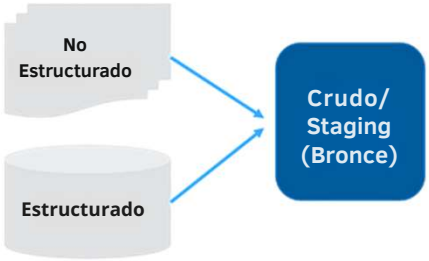
No
Estructurado
Estructurado
Crudo/
Staging
(Bronce)

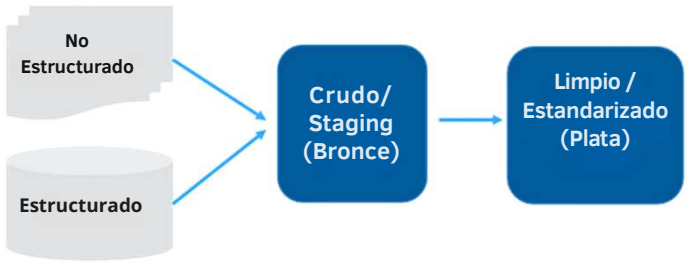
No Estructurado
Estructurado
Crudo/ Staging (Bronce)
Limpio / Estandarizado (Plata)

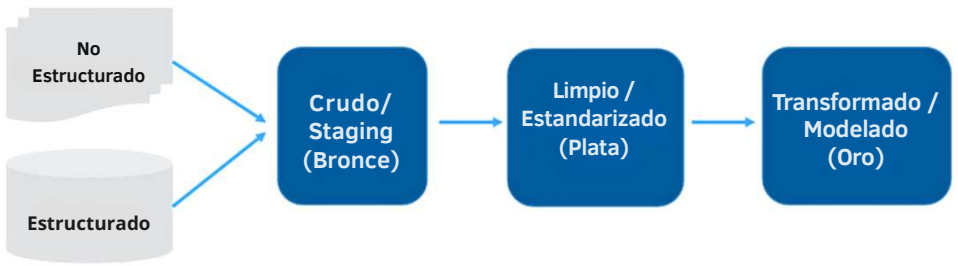
No Estructurado
Estructurado
Crudo/ Staging (Bronce)
Limpio / Estandarizado (Plata)
Transformado / Modelado (Oro)

No Estructurado
Estructurado
Crudo/ Staging (Bronce)
Limpio / Estandarizado (Plata)
Transformado / Modelado (Oro)
BI / Reportes
AI/ML

No Estructurado
Estructurado

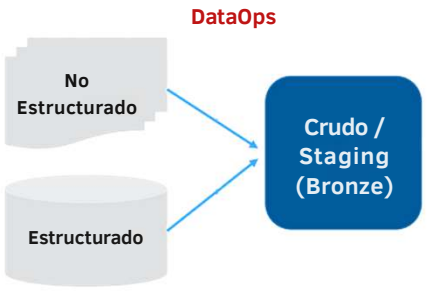
DataOps
No Estructurado
Estructurado
Crudo / Staging (Bronze)

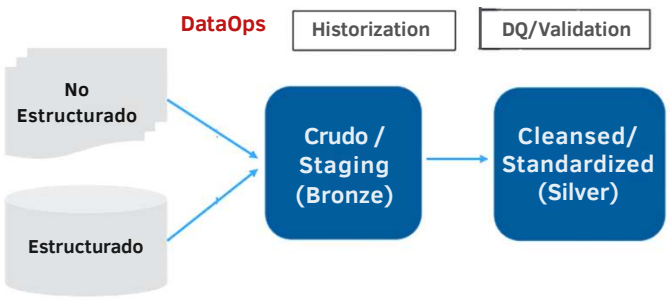
DataOps
Historization
DQ/Validation
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Cleansed/ Standardized (Silver)

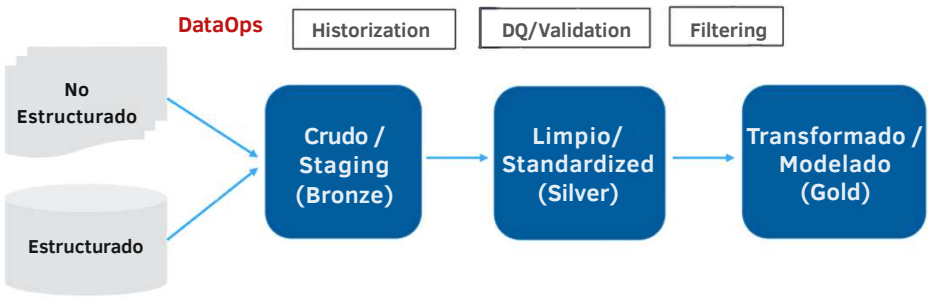
DataOps
Historization
DQ/Validation
Filtering
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Limpio/ Standardized (Silver)
Transformado / Modelado (Gold)

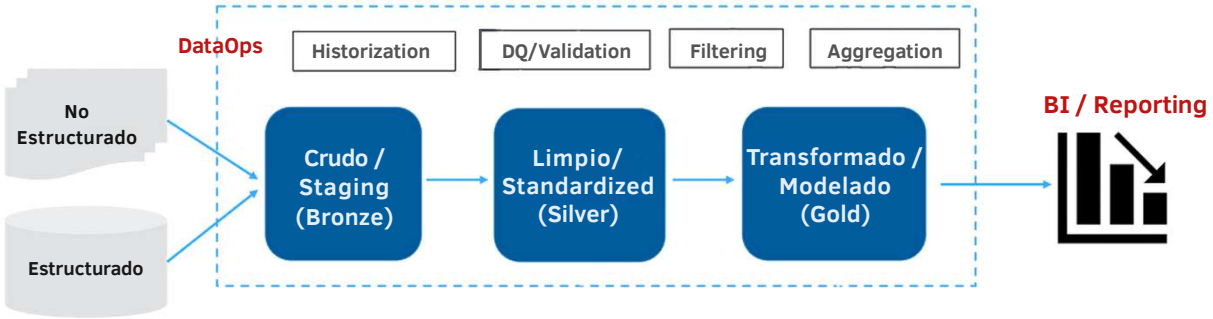
DataOps
Historization
DQ/Validation
Filtering
Aggregation
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Limpio/ Standardized (Silver)
Transformado / Modelado (Gold)
BI / Reporting

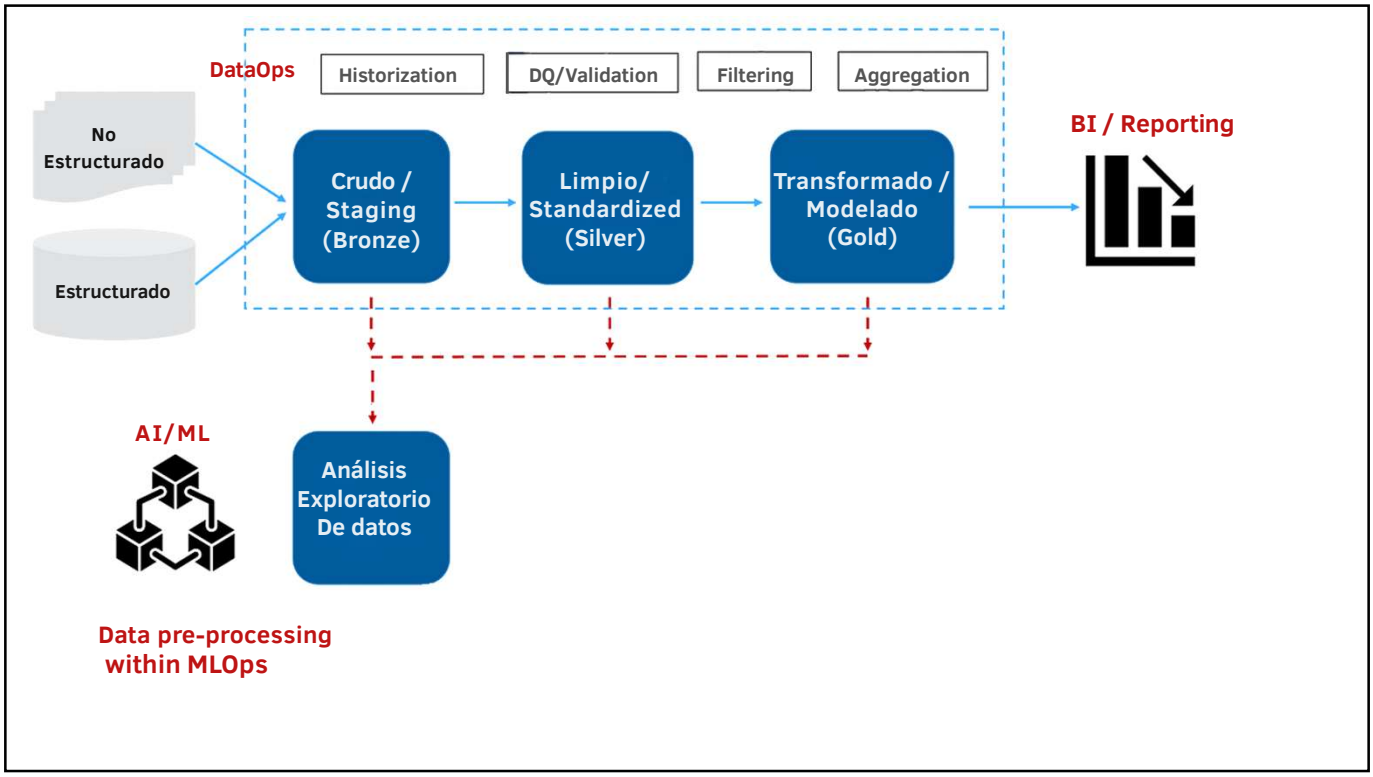
DataOps
Historization
DQ/Validation
Filtering
Aggregation
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Limpio/ Standardized (Silver)
Transformado / Modelado (Gold)
BI / Reporting
AI/ML
Análisis Exploratorio De datos
Data pre-processing within MLOps

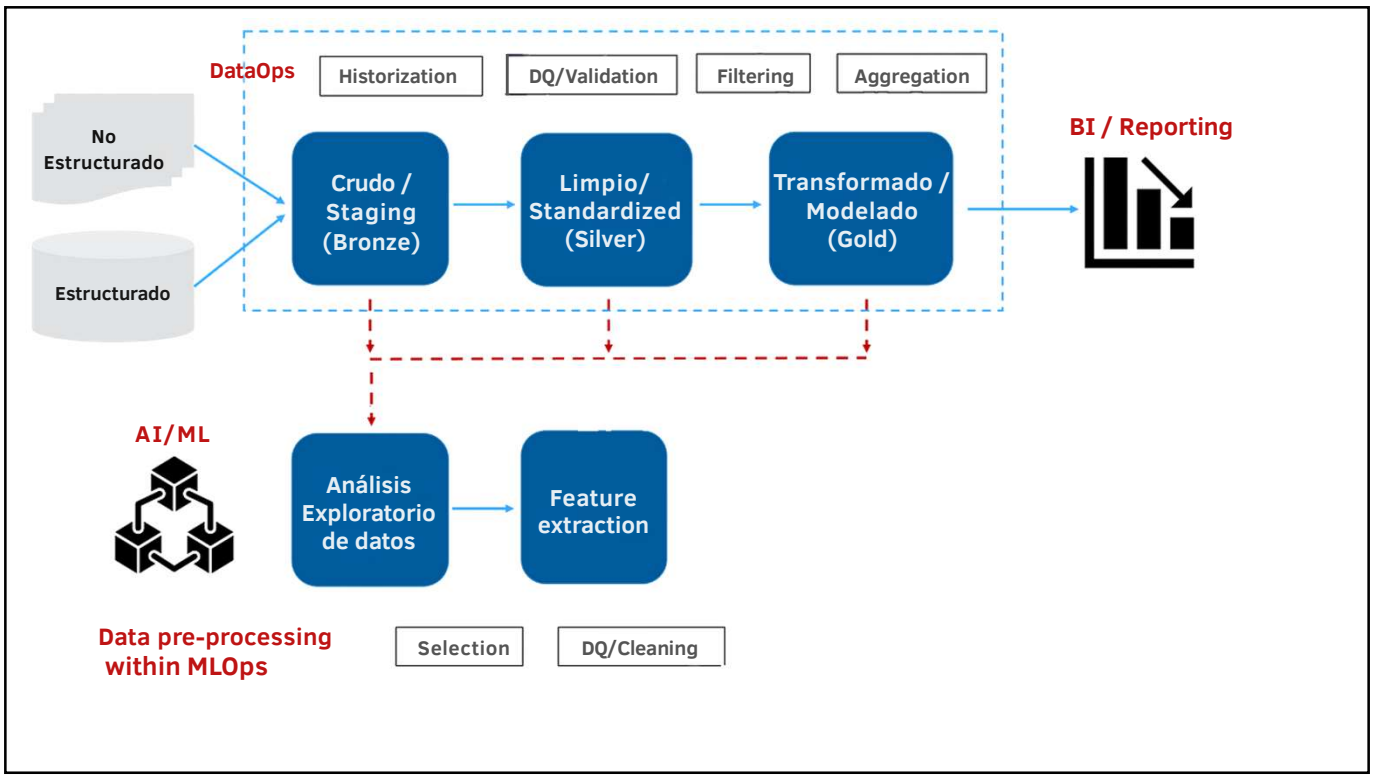
DataOps
Historization
DQ/Validation
Filtering
Aggregation
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Limpio/ Standardized (Silver)
Transformado / Modelado (Gold)
BI / Reporting
AI/ML
Análisis Exploratorio de datos
Feature extraction
Data pre-processing within MLOps
Selection
DQ/Cleaning

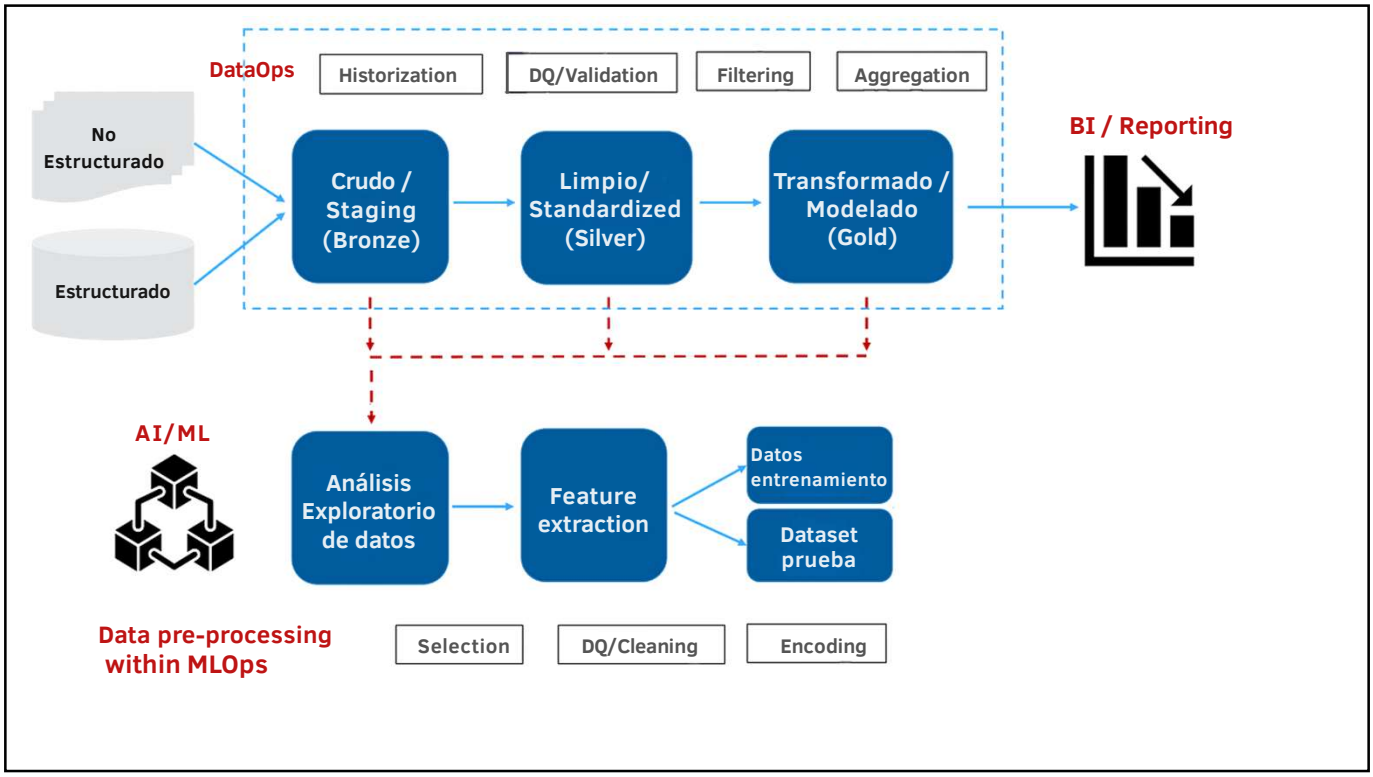
DataOps
Historization
DQ/Validation
Filtering
Aggregation
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Limpio/ Standardized (Silver)
Transformado / Modelado (Gold)
BI / Reporting
AI/ML
Análisis Exploratorio de datos
Feature extraction
Datos entrenamiento
Dataset prueba
Data pre-processing within MLOps
Selection
DQ/Cleaning
Encoding

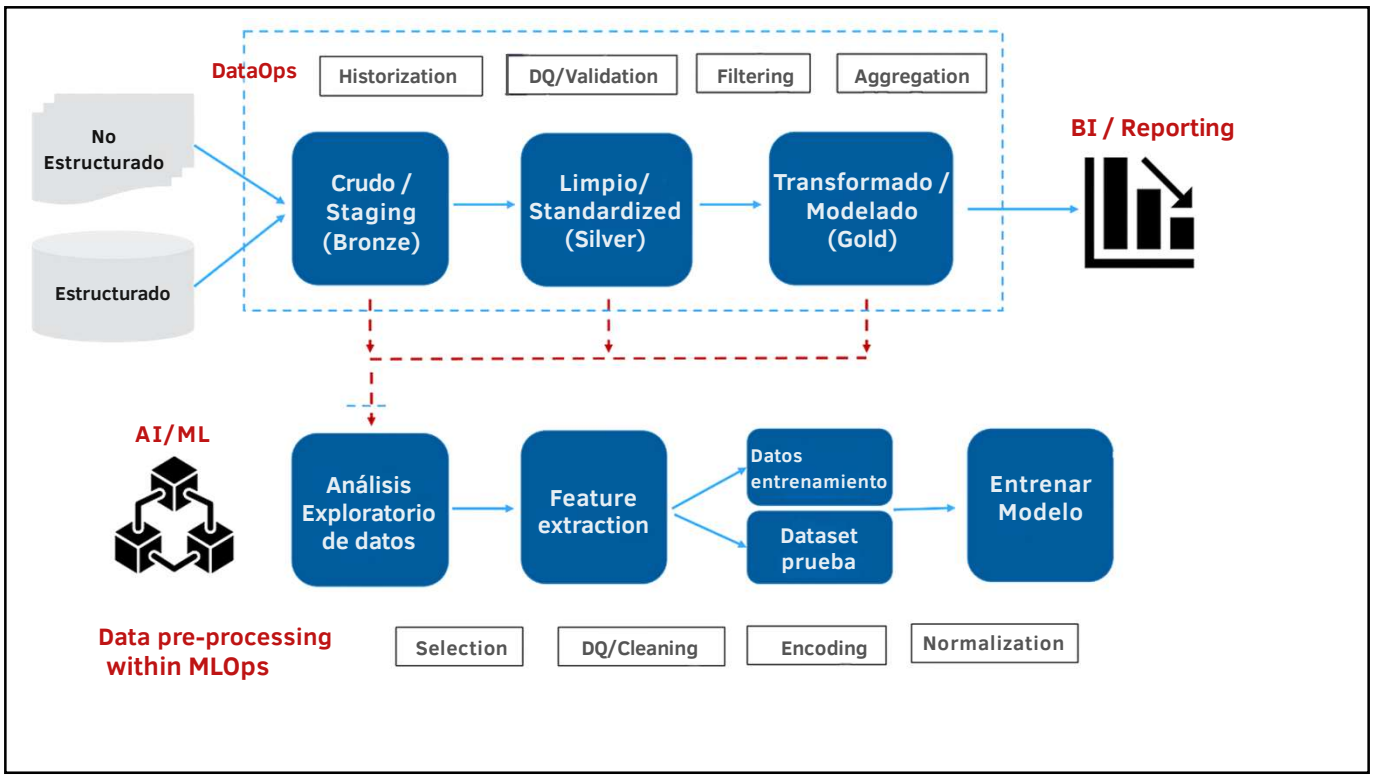
DataOps
Historization
DQ/Validation
Filtering
Aggregation
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Limpio/ Standardized (Silver)
Transformado / Modelado (Gold)
BI / Reporting
AI/ML
Análisis Exploratorio de datos
Feature extraction
Datos entrenamiento
Dataset prueba
Entrenar Modelo
Data pre-processing within MLOps
Selection
DQ/Cleaning
Encoding
Normalization

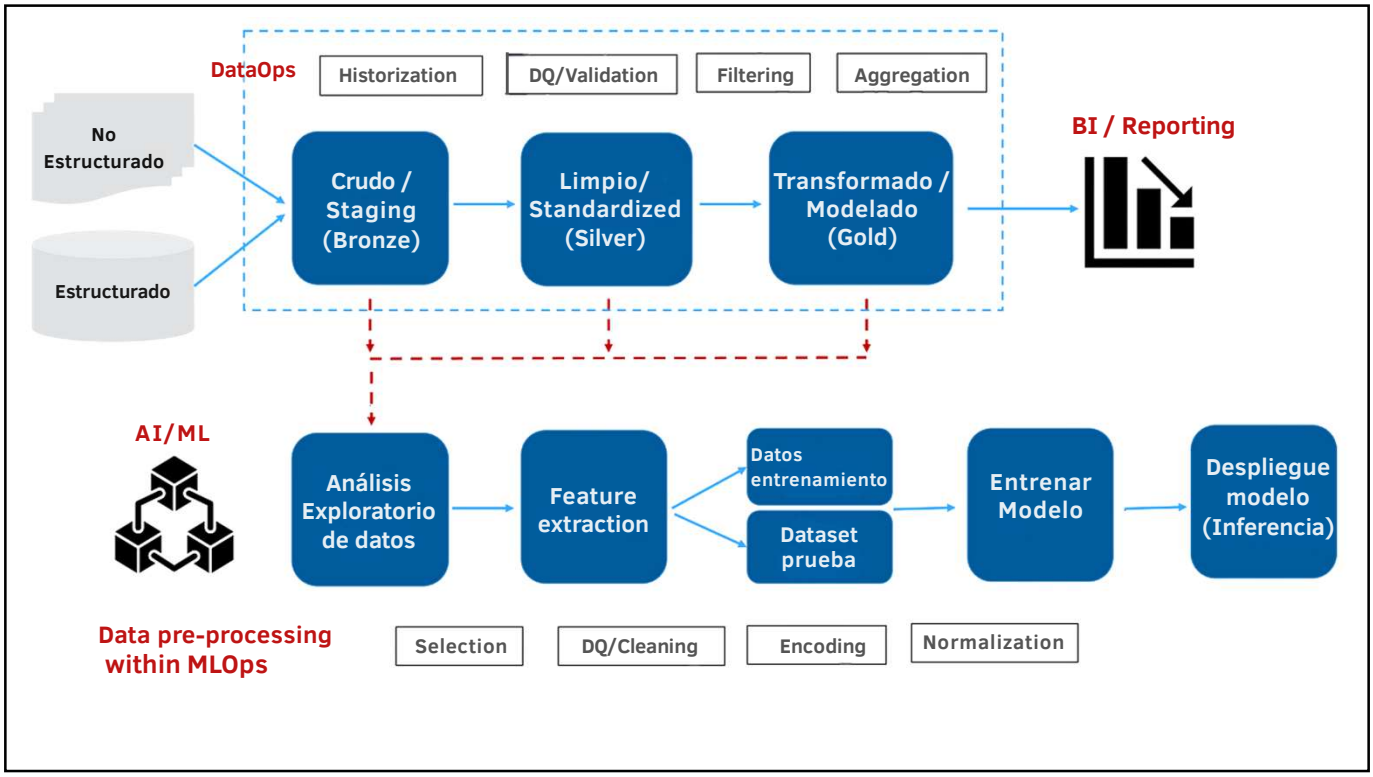
DataOps
Historization
DQ/Validation
Filtering
Aggregation
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Limpio/ Standardized (Silver)
Transformado / Modelado (Gold)
BI / Reporting
AI/ML
Análisis Exploratorio de datos
Feature extraction
Datos entrenamiento
Dataset prueba
Entrenar Modelo
Despliegue modelo (Inferencia)
Data pre-processing within MLOps
Selection
DQ/Cleaning
Encoding
Normalization

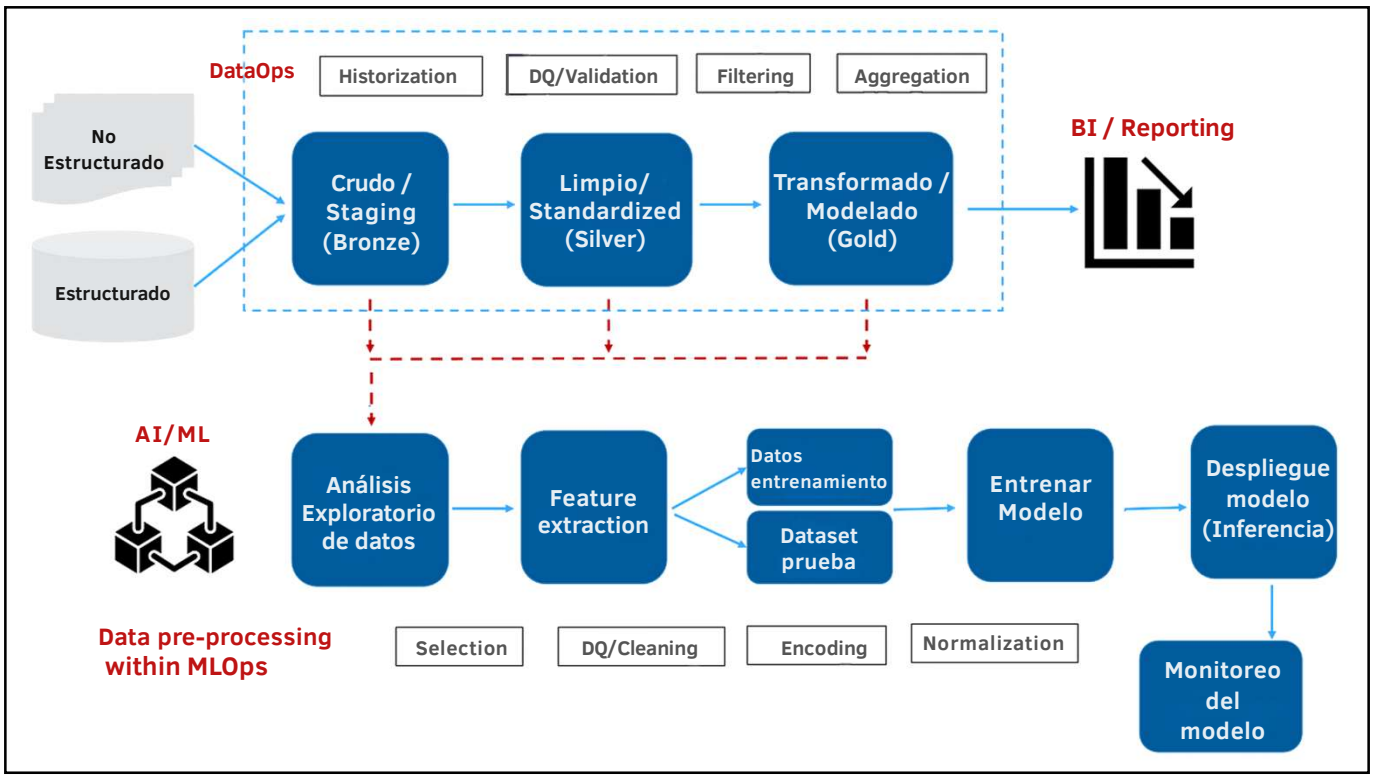
DataOps
Historization
DQ/Validation
Filtering
Aggregation
No Estructurado
Estructurado
Crudo / Staging (Bronze)
Limpio/ Standardized (Silver)
Transformado / Modelado (Gold)
BI / Reporting
AI/ML
Análisis Exploratorio de datos
Feature extraction
Datos entrenamiento
Dataset prueba
Entrenar Modelo
Despliegue modelo (Inferencia)
Data pre-processing within MLOps
Selection
DQ/Cleaning
Encoding
Normalization
Monitoreo del modelo

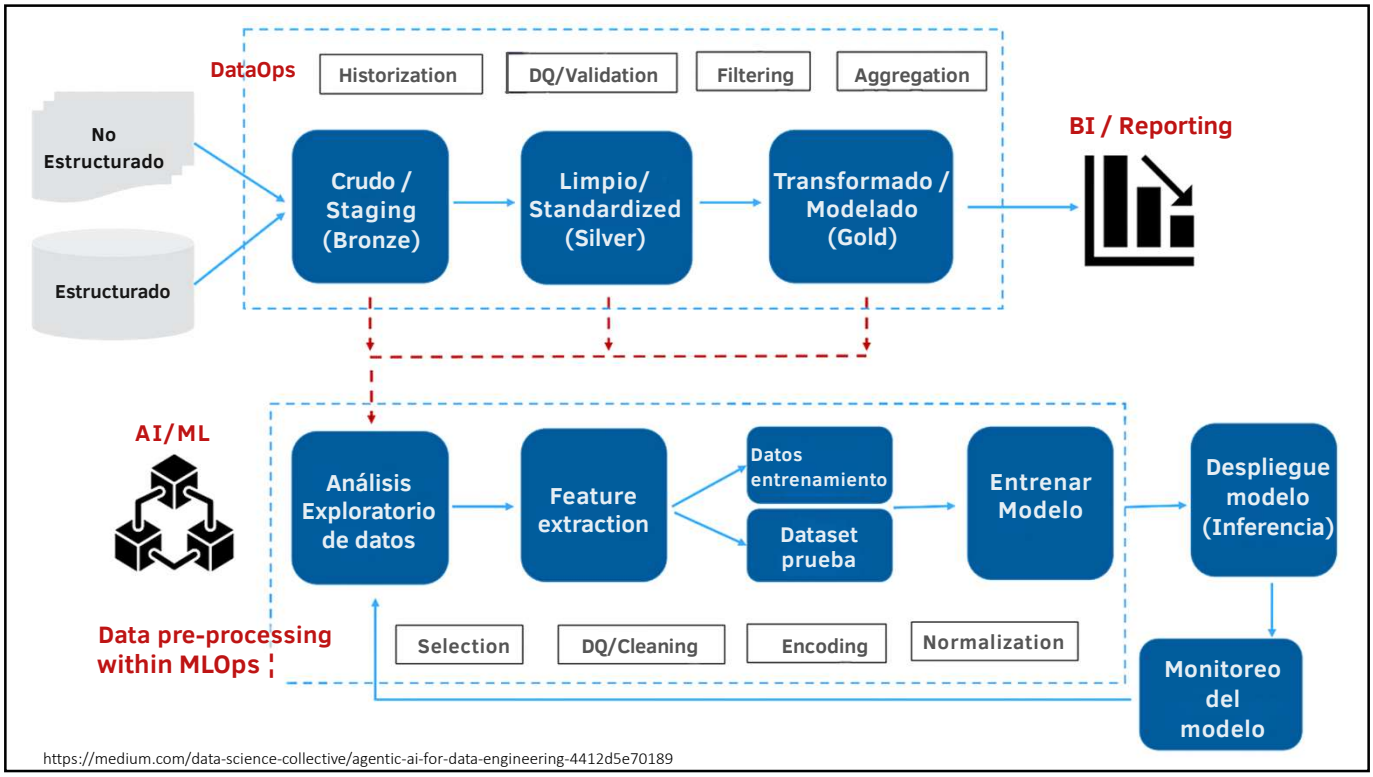

https://medium.com/data-science-collective/agentic-ai-for-data-engineering-4412d5e70189

Conceptos de datos

https://forms.gle/gHjAsCMdEhLyePAN6

Practica de Fabric

https://drive.google.com/drive/folders/1Bllyv8s3P9xp0RNktRDcoIAQ_bchaIqy?usp=sharing

"In God We Trust"

linkedin.com/in/armandoordonez
jaordonez@icesi.edu.co
¡Gracias!
UNIVERSIDAD ICESI A OTRO NIVEL