Outliers

Outliers Buenos vs Outliers Malos

- **ERROR**: Edad de 160 años es un error manual.
- **LIMITE**: Mantener los datos dentro del “grupo promedio”.
- **Point of interest**: “anomalies”: (Objetivo de la anomaly detection)

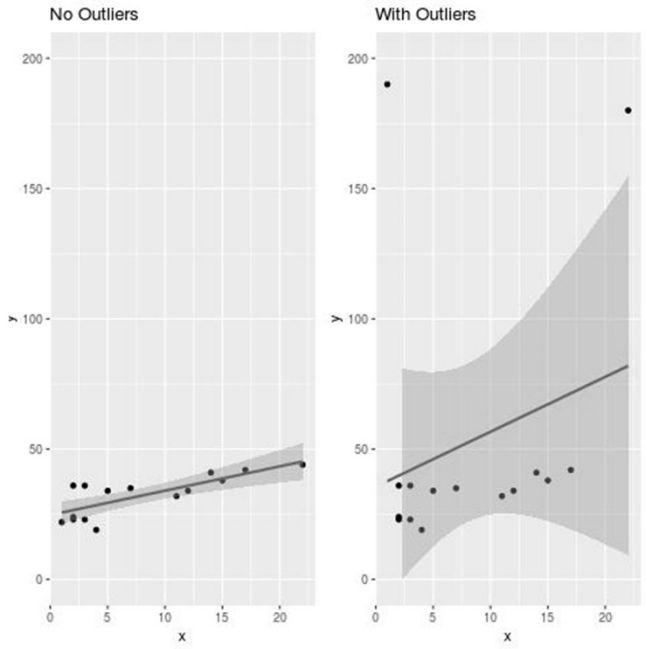

Identificación

- Visual
- Estadística
- Eliminar o transformar
- Univariado vs Multivariado

Visual

- Histograma
- Box plot
- Scatter plot

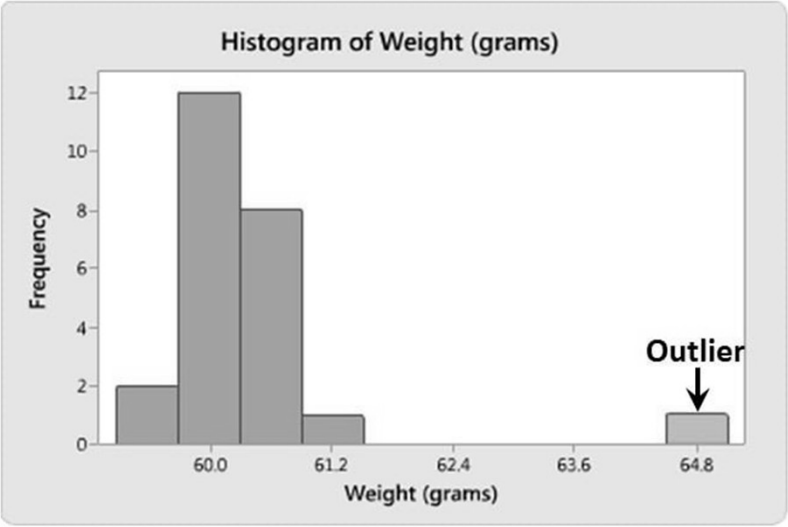

https://blog.minitab.com/hubfs/Imported_Blog_Media/histogramoutlier.jpg

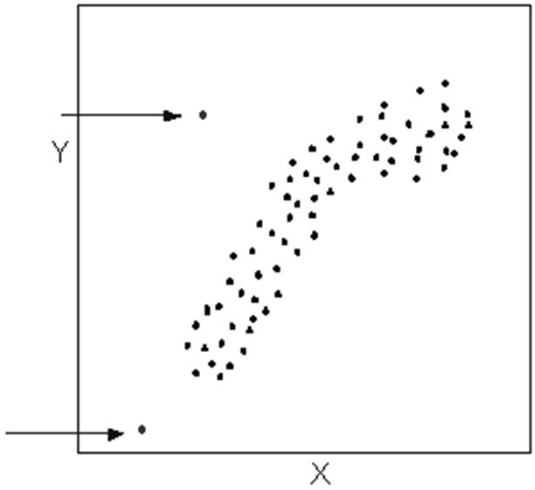

https://statacumen.com/teach/S4R/PDS_book/graphics/scatterplot14.gif

Outliers identification

- Visual
- Estadística
- Eliminar o transformar
- Univariado vs Multivariado

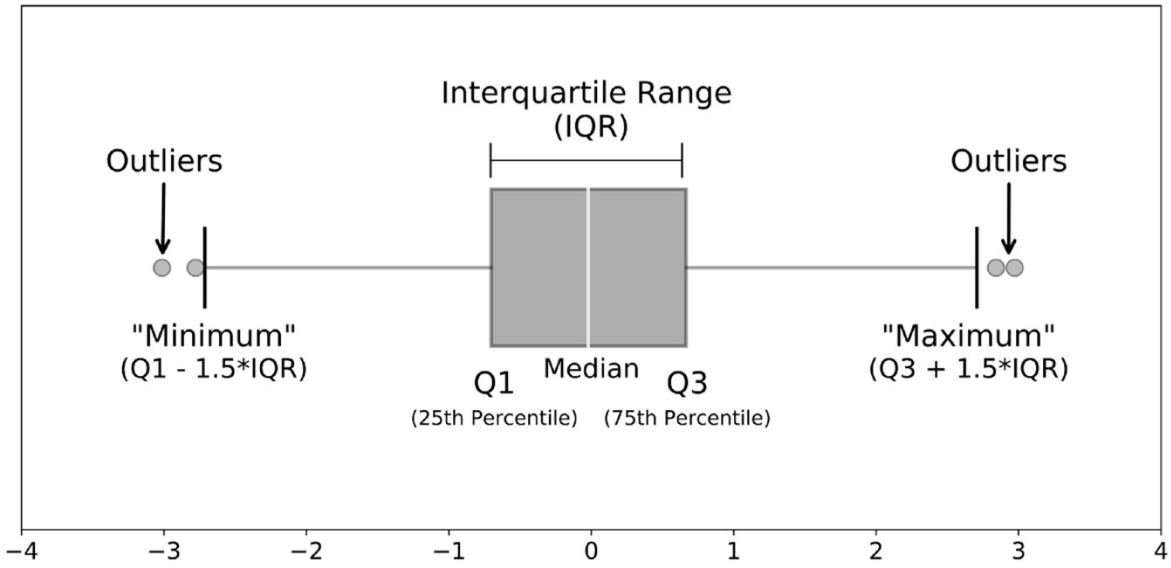

https://miro.medium.com/max/1200/1*0MPDTLn8KoLApoFvI0P2vQ.png

IQR =Q3 - Q1, whereas q3 := 75th quartile and q1 := 25th quartile

*Inner fence = [Q1-1.5*IQR, Q3+1.5*IQR]*

*Outer fence = [Q1−3*IQR, Q3+3*IQR]*

Normal distributions

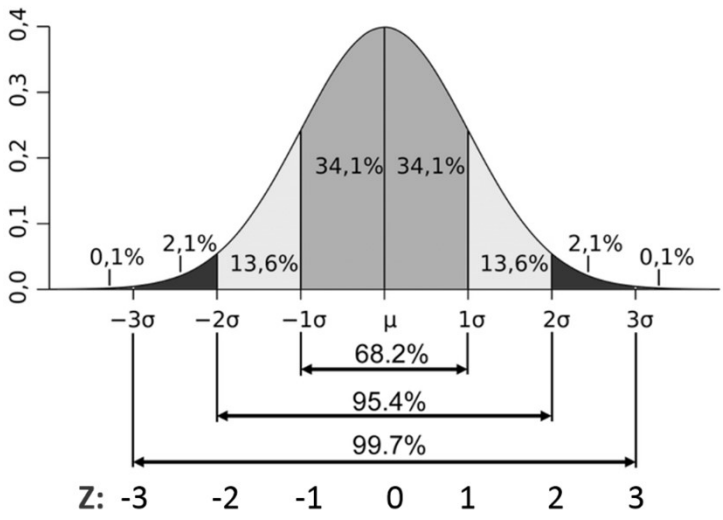

Z-score treatment : The features are normally or approximately normally distributed

Para distribuciones Skewed, filtrado basado en IQR

- Usar regla de proximida Inter-Quartile Range (IQR).
- Data points por debajo de ***Q1 – 1.5 IQR*** o por encima de ***Q3 + 1.5 IQR*** son outliers.

Para otras distribuciones

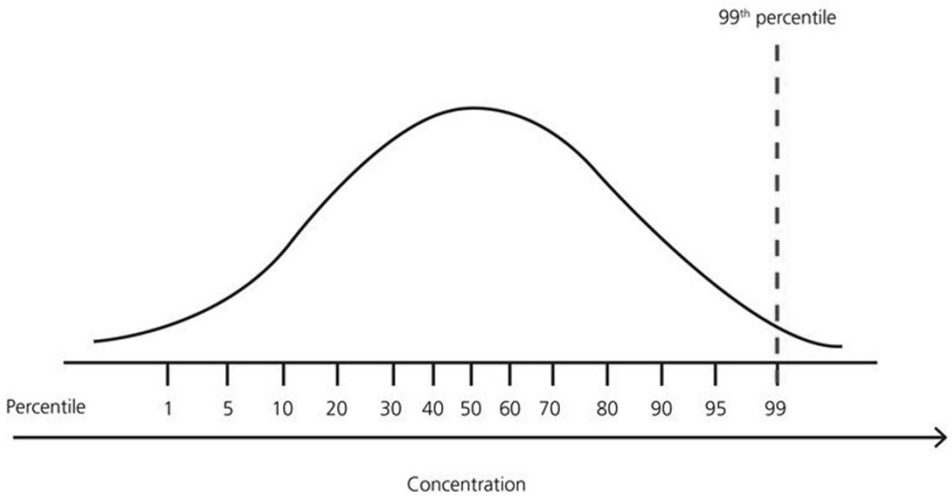

Distancia de Cook

Que tan grande es el cambio en los valores del modelo cuando la observación i^{th} observation se borra. $\mathbf{D_i} = (r_i^2 / p*MSE) * (h_{ii} / (1-h_{ii})^2)$

where:

- $\mathbf{r_i}$ is the ith residual
- **p** is the number of coefficients in the regression model
- **MSE** is the mean squared error
- $\mathbf{h_{ii}}$ is the ith leverage value

Cuanto mayor sea el valor de la distancia de Cook, más influyente será una observación dada.

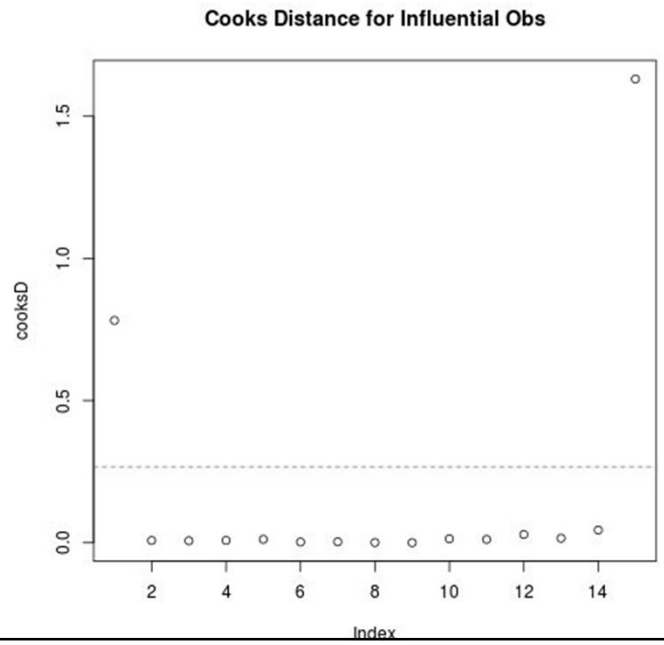

Z-score method

$$z_n = \frac{X_n - \overline{X}}{SD_X}$$

si z > C, donde C generalmente se establece en 3, la observación se marca como un valor atípico.

Outliers identification

- Visual analysis
- statistical methods.
- Drop or transform the outliers.

Outliers identification

- Visual analysis
- statistical methods.
- Drop or transform the outliers.

Como tratar con los outliers?

- Recorte: elimine los valores atípicos
- Límite: Por encima de un valor límite o por debajo de un valor límite, todos los valores se considerarán atípicos.
- Tratar los valores atípicos como un valor faltante
- Discretización: hacer grupos para incluir los valores atípicos en un grupo particular (Binning).

References

- https://towardsdatascience.com/detecting-and-treating-outliers-in-python-part-1-4ece5098b755
- https://careerfoundry.com/en/blog/data-analytics/how-to-find-outliers/
- https://www.aprendemachinelearning.com/deteccion-de-outliers-en-python-anomalia/