3. Unidad 3 - Regularización de Modelos Lineales

📋 **Introducción al Sobreajuste (Overfitting)**

En el aprendizaje automático, los modelos buscan patrones para hacer predicciones precisas. El **sobreajuste** ocurre cuando un modelo aprende "demasiado bien" los detalles y el ruido de los datos de entrenamiento, perdiendo su capacidad para generalizar a datos nuevos.

La Regularización es el conjunto de técnicas que simplifican los modelos penalizando la complejidad, actuando como un freno para evitar que los coeficientes crezcan desmedidamente.

7️⃣ Sesión 7: Fundamentos de Regularización

🧠 Conceptos Teóricos Clave

El Problema: Overfitting

Imagina predecir el precio de una casa. Un modelo sobreajustado podría aprender que "casas con puertas azules valen más" solo porque en el set de entrenamiento así coincidió. Este patrón no es real ni generalizable.

Técnicas de Mitigación

- **L1 (Lasso):** Penaliza el valor absoluto de los coeficientes. Puede llevar algunos coeficientes a cero (selección de variables).
- **L2 (Ridge):** Penaliza el cuadrado de los coeficientes. Reduce su magnitud pero no los elimina.
- **Elastic-Net:** Una combinación lineal de L1 y L2.
- **Otras:** *Dropout* (redes neuronales) y *Pruning* (árboles de decisión).

🌍 Aplicaciones Reales

- **Medicina:** Evita que diagnósticos por imagen se basen en detalles irrelevantes de la captura.
- **Finanzas:** Mejora la detección de fraude ante nuevas tácticas no presentes en el histórico.
- **Vehículos Autónomos:** Permite que la visión por computadora ignore condiciones climáticas específicas del entrenamiento.

📅 Plan de Trabajo - Sesión 7

📝 Antes de la Clase

Preparación teórica necesaria:

- [ ] **Lectura 1:** Multicolinealidad y Bondad de Ajuste
- [ ] **Lectura 2:** Conceptos de Regularización
- [ ] **Lectura 3:** Dilema Bias vs. Variance (Sesgo y Varianza)

📝 Durante la Clase

1. **Discusión:** Implicaciones del sobreajuste en la vida real.
2. **Definiciones:** Importancia de la regularización.
3. **Comparativa:** Fundamentos y diferencias entre **Ridge, LASSO y Elastic-Net**.
4. **Implementación:** Aplicación en modelos de regresión lineal y logística.

📝 Recursos de Sesión 7

- 📁 Notebooks - Sesión 7
- 📂 Datasets - Sesión 7

8️⃣ Sesión 8: Práctica Independiente y Ajuste de Hiperparámetros

⚙️ El Rol de λ (Lambda)

En regularización, el hiperparámetro λ (o α en algunas librerías como Scikit-Learn) controla la fuerza de la penalización:

- $\lambda = 0$**:** Equivale a una regresión estándar (riesgo de Overfitting).
- $\lambda \to \infty$**:** Los coeficientes tienden a cero (riesgo de Underfitting).

📅 Plan de Trabajo - Sesión 8

📝 Antes de la Clase

- [ ] **Repaso:** Diferenciar claramente el mecanismo de penalización de Ridge vs. LASSO.
- [ ] **Software:** Verificar instalación de librerías para modelado (Sklearn, Statsmodels).

🔥 Durante la Clase (Taller Práctico)

Actividad principal: Ajuste de un modelo de **regresión logística** con regularización.

1. Carga del conjunto de datos proporcionado.
2. Implementación de **Ridge (L2)** y **LASSO (L1)**.
3. **Experimentación:** Evaluar cómo cambia la precisión del modelo al variar el valor de λ .

📝 Recursos de Sesión 8

- 📁 Notebooks (Sesion 8)

📚 Material de Referencia Adicional

📖 Bibliografía Recomendada

- **Libro Guía:** Myers, R., Montgomery, D., Vining, G. and Robinson, T. (2012). *The Generalized Linear Model with Applications in Engineering and the Sciences*. John Wiley & Sons.

- **Temas sugeridos:** Revisar el capítulo sobre modelos lineales generalizados y penalización.